SIECI NEURONOWE

Sprawozdanie z ćwiczenia laboratoryjnego nr 2

Regresja logistyczna uczona metodą gradientową

wpływ współczynnika uczenia, inicjalizacji i warunku stopu na zbieżność

Imię i nazwisko: .....

Nr albumu: .....

Termin zajęć: .....

Data oddania: .....

1. Cel ćwiczenia

Celem ćwiczenia była samodzielna implementacja regresji logistycznej uczonej metodą spadku gradientu i zastosowanie jej do klasyfikacji zbioru Heart Disease. Regresję logistyczną można traktować jako najprostszą, jednowarstwową sieć neuronową. Zbadano:

- jakość klasyfikacji (precision, recall, F1),
- wpływ współczynnika uczenia α na zbieżność,
- wpływ rozkładu inicjalizacji wag,
- wpływ liczby epok i warunku stopu (krzywe uczenia).

Główne pytanie: czy klasyfikator liniowy zawsze zbiega do globalnego minimum i czy zła parametryzacja uniemożliwia zbieżność, czy tylko ją wydłuża?

2. Model i implementacja

2.1. Model

Model zwraca prawdopodobieństwo, że pacjent jest chory:

- **wyjście:** $p(x) = \sigma(Wx + b)$, gdzie $\sigma(z) = 1 / (1 + e^{(-z)})$,
- **koszt:** średnia entropia krzyżowa $L = -(1/N) \Sigma [y \ln p + (1 - y) \ln(1 - p)]$,
- **gradient:** $\partial L/\partial w_i = -(1/N) \Sigma (y - p) x_i$, $\partial L/\partial b = -(1/N) \Sigma (y - p)$,
- **aktualizacja:** $w \leftarrow w - \alpha \partial L/\partial w$ (pełny batch – wszystkie próbki w każdej epoce).

Funkcja kosztu jest wypukła, więc ma co najwyżej jedno minimum i nie ma minimów lokalnych. Klasyfikacja: klasa 1, gdy $p \geq 0{,}5$.

2.2. Implementacja

Model zaimplementowano w NumPy w klasie LogisticRegressionGD (plik logreg.py), bez gotowych metod uczenia. Najważniejsze elementy:

- sigmoida w wersji stabilnej numerycznie (brak przepełnienia exp dla dużych |z|),
- trzy warunki stopu: stała liczba epok, $|L_t - L_{(t-1)}| < tol$ oraz early stopping na koszcie walidacyjnym z przywróceniem najlepszych wag,
- w każdej epoce zapisywane są koszt, F1, precision, recall (trening i walidacja) oraz norma gradientu – z nich powstają krzywe uczenia,
- scikit-learn użyto tylko do kontroli wyniku i metryk.

2.3. Dane

Wykorzystano przygotowanie danych z ćwiczenia 1 (data.py): uzupełnienie braków dominantą, kodowanie one-hot i standaryzację. Każda próbka ma 17 cech. Podział warstwowy: 181 próbek treningowych, 61 walidacyjnych i 61 testowych (46% chorych w każdym zbiorze).

2.4. Minimum globalne i testy poprawności

Jako punkt odniesienia wyznaczono minimum kosztu długim treningiem ($\alpha = 0{,}5$, do $|\Delta L| < 10^{-14}$): $L^* = 0{,}287171$ przy normie gradientu $1{,}4 \cdot 10^{-7}$. Za zbieżność przyjęto osiągnięcie $L \le L^* + 10^{-3}$. Poprawność implementacji sprawdzono testami (plik test_logreg.py):

Tabela 1. Testy poprawności implementacji

Test	Wynik
gradient analityczny vs różnice skończone	różnica $8{,}8 \cdot 10^{-11}$
sigmoida dla z = ±1000	brak NaN, $\sigma(0) = 0{,}5$
precision / recall / F1 vs scikit-learn	identyczne
koszt przy w = 0 i jego przebieg	ln 2 = 0,693, maleje monotonicznie
minimum vs LogisticRegression (bez regularyzacji)	różnica kosztu $1{,}1 \cdot 10^{-12}$

3. Model bazowy

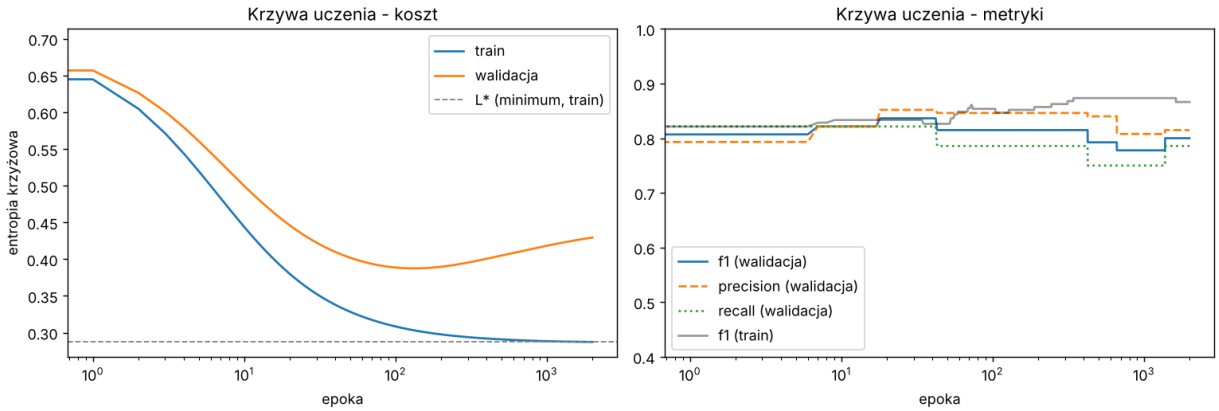
Model bazowy: $\alpha = 0{,}1$, wagi początkowe zerowe, 2000 epok. Wyniki przedstawiono w tabeli 2 i na rysunku 1.

Tabela 2. Wyniki modelu bazowego

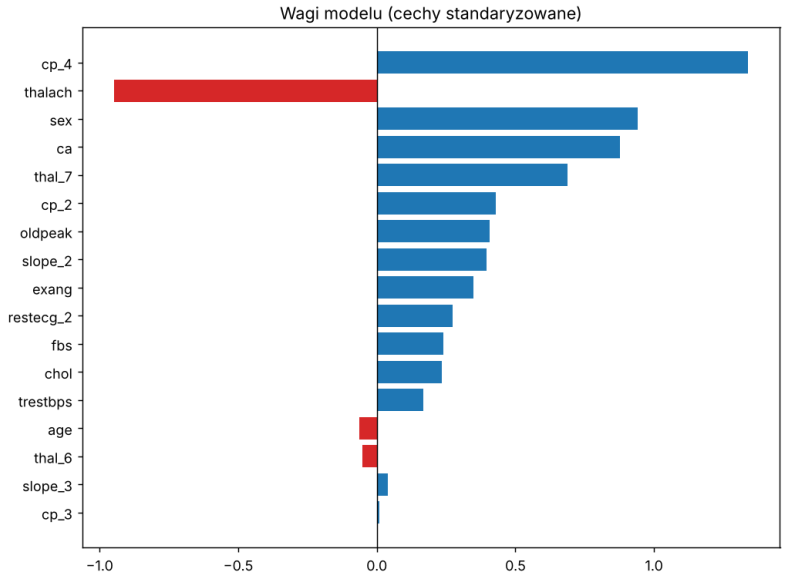
Zbiór	Precision	Recall	F1	Accuracy
treningowy	0,919	0,819	0,866	0,884
walidacyjny	0,815	0,786	0,800	0,820
testowy	0,786	0,786	0,786	0,803

Obserwacje:

- zbieżność do $L^* + 10^{-3}$ po 1067 epokach,
- na zbiorze testowym 22 z 28 chorych wykrytych, 6 fałszywych alarmów,
- wynik jest bliski baseline z ćw. 1 (F1 = 0,821); tamten model uczono na 242 próbkach (train + val), więc nie jest to porównanie 1:1,
- największe wagi mają cp_4 (1,34), thalach (−0,95, ujemna), sex (0,94), ca (0,88) i thal_7 (0,69) – te same cechy, które w ćw. 1 miały najsilniejszą korelację z chorobą (rys. 2).



Rysunek 1. Krzywe uczenia modelu bazowego: koszt (lewo) i metryki (prawo)



Rysunek 2. Wagi modelu po uczeniu (cechy standaryzowane)

4. Wpływ współczynnika uczenia

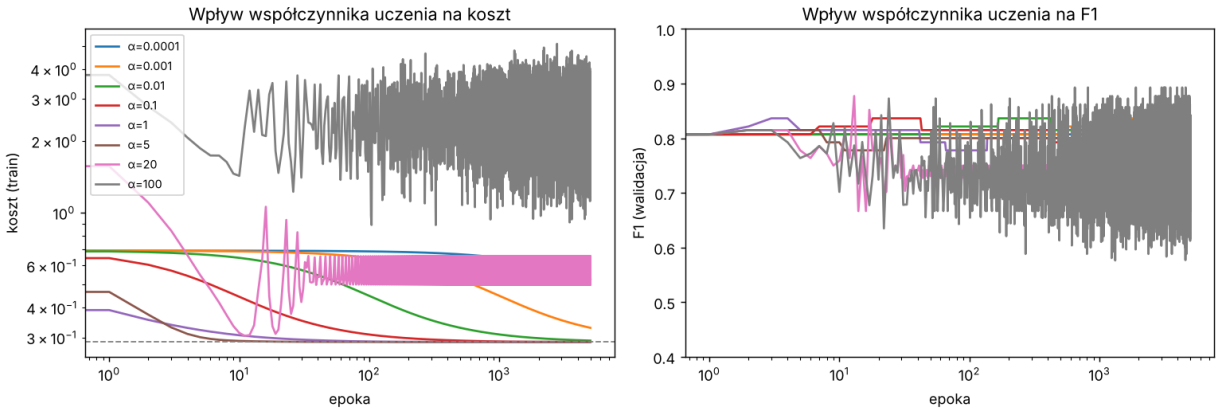
Model uczono przez 5000 epok z inicjalizacją zerową dla ośmiu wartości α (tabela 3, rys. 3 i 4).

Tabela 3. Wpływ współczynnika uczenia α

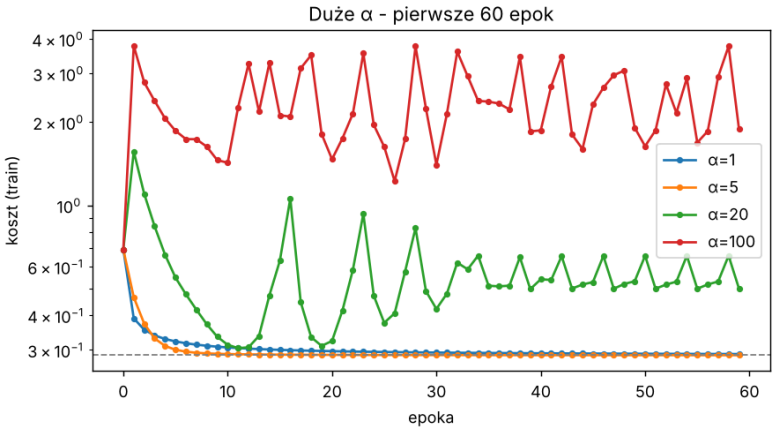
α	Koszt końcowy	Epoki do zbieżności	Oscylacje	F1 val	F1 test
0,0001	0,5247	brak	nie	0,807	0,772
0,001	0,3291	brak	nie	0,815	0,772
0,01	0,2908	brak (blisko)	nie	0,792	0,793
0,1	0,2872	1067	nie	0,800	0,772
1	0,2872	106	nie	0,800	0,772
5	0,2872	18	nie	0,800	0,772
20	0,4996	nigdy	tak	0,727	0,807
100	1,8651	nigdy	tak	0,755	0,741

Obserwacje:

- **α ≤ 0,01** – koszt maleje stabilnie, ale za wolno; po 5000 epokach model nie dochodzi do minimum,
- **0,1 ≤ α ≤ 5** – zbieżność do tego samego L*; liczba epok maleje prawie odwrotnie proporcjonalnie do α (1067 → 106 → 18),
- **α ≥ 20** – krok „przeskakuje” minimum i koszt oscyluje (dla α = 100 między 0,9 a 4,5); minimum istnieje, ale optymalizator do niego nie dochodzi,
- wyższe F1 testowe przy α = 20 to przypadek – na 61 próbkach jedna próbka zmienia F1 o ok. 0,02, a F1 nie jest funkcją minimalizowaną.



Rysunek 3. Wpływ α na koszt treningowy (lewo) i F1 walidacyjne (prawo)



Rysunek 4. Pierwsze 60 epok dla dużych wartości α

5. Wpływ inicjalizacji wag

Porównano inicjalizację zerową, stałą oraz losową z rozkładu normalnego N(0, σ) i jednostajnego U(−a, a). Dla rozkładów losowych wykonano po 10 przebiegów z różnymi ziarnami (α = 0,1, 5000 epok). ‖w − w*‖ to odległość wag końcowych od wag w minimum.

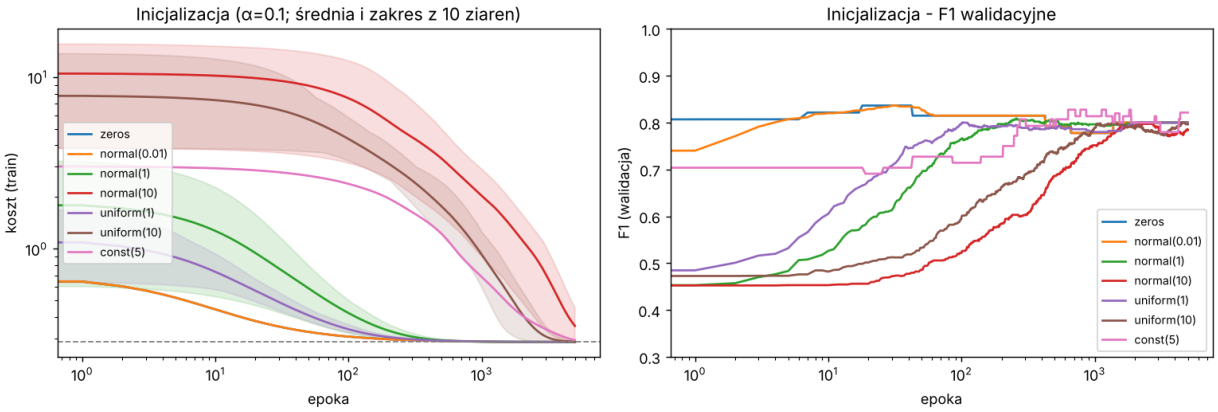
Tabela 4. Wpływ inicjalizacji (średnie z 10 przebiegów)

Inicjalizacja	Koszt start	Koszt końcowy	Epoki do zbieżności	Nie zbiegło	F1 test	‖w − w*‖
zera	0,693	0,2872	1067	0 / 1	0,772	0,013
N(0; 0,01)	0,694	0,2872	1065	0 / 10	0,772	0,013
N(0; 1)	1,87	0,2872	987	0 / 10	0,772	0,009
U(−1; 1)	1,15	0,2872	1168	0 / 10	0,772	0,015
U(−10; 10)	7,81	0,2879	3761	2 / 10	0,787	0,28
N(0; 10)	10,50	0,3558	–	10 / 10	0,823	3,96
stała 5	3,02	0,2943	–	1 / 1	0,807	1,35

Obserwacje:

- **małe inicjalizacje** (zera, N(0; 0,01), N(0; 1), U(−1; 1)) – wszystkie dochodzą do tego samego minimum w podobnej liczbie epok,

- **duże inicjalizacje** (N(0; 10), U(−10; 10), stała 5) – startują z bardzo dużym kosztem i nasyconą sigmoidą (p ≈ 0 lub 1), przez co gradient jest mały i uczenie trwa dużo dłużej,
- mimo to ‖w − w*‖ cały czas maleje – przy dłuższym treningu wszystkie inicjalizacje trafiają do tego samego punktu, bo wypukła funkcja nie ma minimów lokalnych,
- zła inicjalizacja wydłuża uczenie, ale nie zmienia jego wyniku.



Rysunek 5. Wpływ inicjalizacji na koszt (średnia i zakres z 10 ziaren) i F1 walidacyjne

6. Liczba epok i warunek stopu

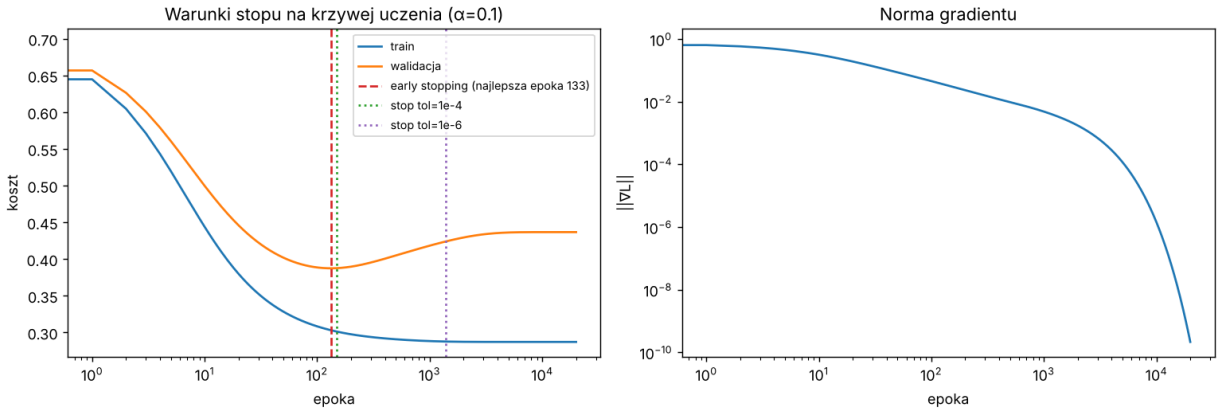
Porównano stałą liczbę epok, zatrzymanie przy małej zmianie kosztu (|ΔL| < tol) oraz early stopping, który kończy uczenie, gdy koszt walidacyjny nie poprawia się przez 50 epok (α = 0,1).

Tabela 5. Wpływ warunku stopu

Warunek stopu	Epoki	Koszt train	Koszt val	F1 val	F1 test
stałe 10 epok	10	0,444	0,500	0,821	0,772
stałe 100 epok	100	0,308	0,389	0,815	0,764
stałe 1000 epok	1000	0,288	0,418	0,778	0,786
stałe 20 000 epok	20 000	0,287	0,437	0,800	0,772
$\|\Delta L\| < 10^{-4}$	148	0,301	0,388	0,815	0,786
$\|\Delta L\| < 10^{-6}$	1400	0,288	0,424	0,800	0,786
early stopping	183 (najl. 133)	0,303	0,387	0,815	0,764

Obserwacje:

- koszt treningowy maleje monotonicznie do L*, a norma gradientu spada z ok. 0,7 do 10^{-11} – uczenie jest stabilne,
- koszt walidacyjny ma minimum ok. 133. epoki (0,387), a potem rośnie do 0,437 – model zaczyna przeuczać się na 181 próbkach (predykcje stają się zbyt pewne),
- F1 prawie się nie zmienia, bo zależy tylko od strony progu 0,5, a koszt również od pewności predykcji,
- $|\Delta L| < 10^{-4}$ i early stopping kończą uczenie po ok. 150 epokach z tymi samymi metrykami co trening przez 20 000 epok.



Rysunek 6. Warunki stopu na krzywej uczenia (lewo) i norma gradientu (prawo)

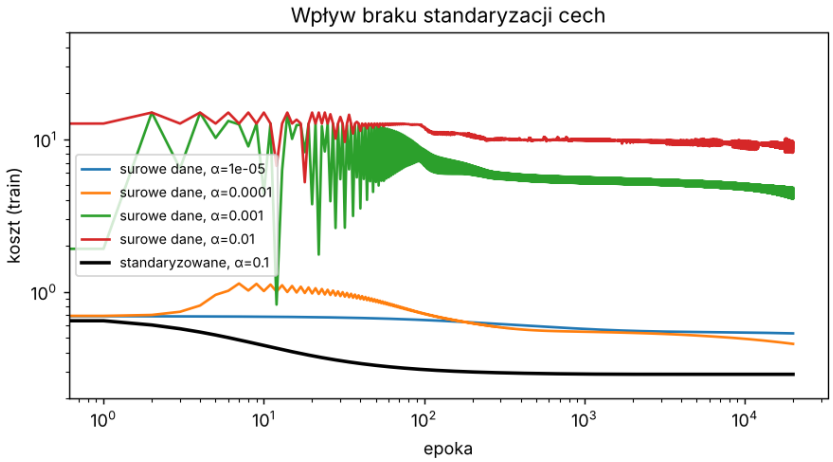
7. Zła parametryzacja danych: brak standaryzacji

Ten sam model uczono na surowych cechach (cholesterol ok. 250, oldpeak ok. 1). Minimum jest takie samo jak dla danych standaryzowanych, ale zmienia się kształt funkcji kosztu: wskaźnik uwarunkowania macierzy X^TX rośnie z 46 do $5{,}5 \cdot 10^6$.

Tabela 6. Uczenie na danych niestandaryzowanych (20 000 epok)

Dane i α	Koszt końcowy	F1 test
surowe, $\alpha = 10^{-5}$	0,533	0,621
surowe, $\alpha = 10^{-4}$	0,455	0,667
surowe, $\alpha = 10^{-3}$	4,79 (oscylacje)	0,691
surowe, $\alpha = 10^{-2}$	8,97 (oscylacje)	0,675
standaryzowane, α = 0,1	0,287	0,772

- nie istnieje dobre α: krok bezpieczny dla „stromego” kierunku (chol) jest za mały dla „płaskich” kierunków,
- po 20 000 epok koszt jest daleko od minimum – brak standaryzacji w praktyce uniemożliwia zbieżność.



Rysunek 7. Uczenie na danych surowych i standaryzowanych

8. Wnioski

Przy dobrze dobranym α i małych wagach początkowych model zawsze dochodził do tego samego minimum L* = 0,287, co wynika z wypukłości funkcji kosztu. Zbyt małe α i duża inicjalizacja tylko wydłużały uczenie, bo model dalej zmierzał do tego samego punktu, tylko potrzebował tysięcy epok zamiast setek. Zbyt duże α (≥ 20) i brak standaryzacji w praktyce uniemożliwiały zbieżność, bo krok przeskakiwał minimum albo był za mały w części kierunków. Najlepiej sprawdzało się α od 1 do 5, które dochodziło do minimum w kilkadziesiąt do stu epok bez oscylacji. Najniższy koszt treningowy nie oznacza najlepszego modelu: koszt walidacyjny był najmniejszy ok. 133. epoki, więc early stopping lub stop przy $|\Delta L| < 10^{-4}$ daje ten sam wynik (F1 ≈ 0,79) dużo szybciej.

Uwaga: kod w plikach logreg.py (model i eksperymenty), test_logreg.py (testy) i data.py (przygotowanie danych z ćw. 1). Przy kodzie korzystano z narzędzia AI (Claude), co oznaczono w plikach zgodnie z pkt 11 regulaminu.