Sieci neuronowe – ćwiczenie 3

Wielowarstwowa sieć neuronowa uczona propagacją wsteczną · zbiór Heart Disease (Cleveland)

Dawid Pilarski **Nr albumu:** 280468

> Kod przygotowany z pomocą narzędzia AI (Claude), oznaczony zgodnie z pkt 11 regulaminu.

Najważniejsze wyniki

implementacja	moduły Linear, ReLU, sigmoida + entropia krzyżowa z `forward` i `backward`; gradient zgodny z numerycznym do ok. 10^{-10}
sieć 17-17-1 (α = 0,01, wagi N(0; 0,01))	przez ok. **720 epok** stoi na koszcie 0,69, potem się uczy; najlepsza na walidacji w epoce **1783**: test **F1 = 0,764**
przeuczenie	po 30 000 epok koszt treningowy 0,031, walidacyjny rośnie z 0,393 do **0,909**
szerokość warstwy ukrytej	2 → 256 neuronów: plateau krótsze (1055 → 428 epok), F1 przy early stopping ~0,76 dla każdej szerokości
normalizacja	dane surowe: regresja logistyczna się rozbiega, MLP utyka na koszcie 0,52 (F1 0,67); min-max i standaryzacja działają
liczba warstw	0 / 1 / 2 / 3 warstwy: wyjście z plateau po ok. 22 / 765 / 7700 / 94 600 epokach; **4 warstwy nie ruszają** w 150 000 epok
przyczyna	gradient maleje kilka do kilkudziesięciu razy na każdą warstwę w stronę wejścia; inicjalizacja He usuwa plateau (24–55 epok)

Spis treści: 1. Cel · 2. Model i implementacja · 3. Model bazowy · 4. Szerokość warstwy ukrytej · 5. Dane znormalizowane i nieznormalizowane · 6. Liczba warstw · 7. Dodatkowo: inicjalizacja He · 8. Podsumowanie · 9. Wnioski

1. Cel ćwiczenia

Implementacja wielowarstwowej sieci neuronowej (MLP) z funkcją aktywacji **ReLU** i funkcją kosztu jak w regresji logistycznej (sigmoida + entropia krzyżowa), uczonej **algorytmem propagacji wstecznej**. Każda operacja jest osobnym modułem z `forward` i `backward`, a gradienty wag liczone są regułą łańcuchową od kosztu w stronę wejścia.

Badam, jak sieć zachowuje się na zbinaryzowanym zbiorze Heart Disease dla:

- różnej **wymiarowości warstwy ukrytej**: znacznie mniejszej od liczby cech, równej jej i znacznie większej,
- danych **znormalizowanych i nieznormalizowanych**,

- różnej **liczby warstw**.

Zgodnie z treścią wagi inicjalizuję z rozkładu Gaussa N(0; 0,01), a współczynnik uczenia to α = 0,01 (pełny batch).

2. Model i implementacja

2.1. Propagacja wsteczna jako sekwencja modułów

Sieć to złożenie operacji $L(f_K(\dots f_2(f_1(x))))$. Reguła łańcuchowa daje $\frac{\partial L}{\partial x_{k-1}} = \frac{\partial L}{\partial x_k}\,\frac{\partial x_k}{\partial x_{k-1}}$, więc każdy moduł potrzebuje tylko dwóch funkcji:

- `forward(x)`: liczy wyjście i **zapamiętuje wejście** (będzie potrzebne przy przejściu wstecz),
- `backward(dL/dy)`: liczy gradient po swoich wagach (jeśli je ma) i **zwraca** $\partial L/\partial x$ dla modułu poprzedniego.

Przejście w przód idzie w kolejności operacji, przejście wstecz w kolejności odwrotnej.

moduł	forward	backward (dla jednego przykładu, $\partial L/\partial y$ – wektor wierszowy)
Linear	$y = Wx + b$	$\frac{\partial L}{\partial W} = (\frac{\partial L}{\partial y})^T x^T$, $\frac{\partial L}{\partial b} = \frac{\partial L}{\partial y}$, $\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} W$
ReLU	$y = \max(0, x)$	$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} \odot [x > 0]$ (macierz diagonalna → mnożenie element-wise)
sigmoida + BCE	$p = \sigma(z)$, $L = -\frac{1}{N}\sum[y \ln p + (1 - y)\ln(1 - p)]$	$\frac{\partial L}{\partial z} = \frac{p - y}{N}$ (jak w ćw. 2)

W kodzie wiersz macierzy X to jeden przykład, więc paczka N przykładów ma kształt (N, d), a $\partial L/\partial y$ kształt (N, d_y): to ta sama konwencja co w treści, tylko dla wielu przykładów naraz. Gradient wag to suma po przykładach: `dW = dY.T @ X`.

Sieć ma postać: Linear → ReLU → … → Linear → sigmoida + BCE. Bez warstw ukrytych to dokładnie regresja logistyczna z ćw. 2.

2.2. Implementacja (NumPy, bez gotowych metod uczenia)

2.3. Dane

Przygotowanie z ćw. 1 (`data.py`): braki uzupełnione dominantą, cechy kategoryczne zakodowane one-hot, standaryzacja parametrami ze zbioru treningowego, podział warstwowy 60/20/20. Wariant **min-max** (zakres [0, 1]) i dane **surowe** liczę z tych samych kolumn przed standaryzacją.

	liczba pacjentów	odsetek chorych	liczba cech
treningowy	181	0.459	17
walidacyjny	61	0.459	17
testowy	61	0.459	17

2.4. Testy poprawności propagacji wstecznej

Gradient z `backward` porównuję z gradientem numerycznym $\frac{L(w+h) - L(w-h)}{2h}$ dla **każdej wagi** sieci z dwiema warstwami ukrytymi. Dodatkowo sieć bez warstw ukrytych musi dawać ten sam gradient co wzór z ćw. 2: $-\frac{1}{N} X^T (y - p)$.

	max |dW − dW_num|	max |db − db_num|
warstwa liniowa 1 5→6	1.0e-10	9.4e-11
warstwa liniowa 2 6→4	1.1e-10	2.9e-11
warstwa liniowa 3 4→1	9.8e-11	4.7e-11
0 warstw ukrytych vs wzór z ćw. 2	2.2e-16	—

> **Wniosek:** gradienty z propagacji wstecznej zgadzają się z numerycznymi do ok. 10^{-10} w każdej warstwie, a sieć bez warstw ukrytych liczy dokładnie gradient regresji logistycznej. Implementacja jest poprawna.

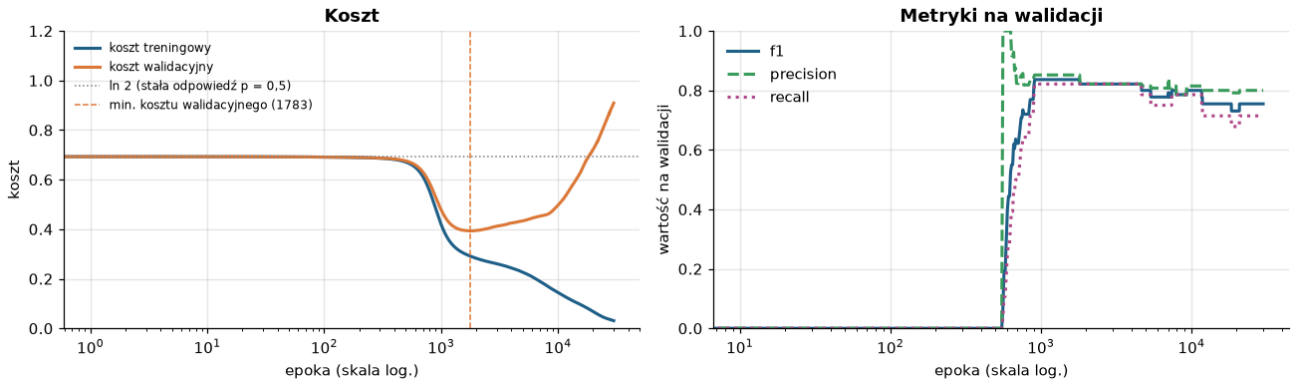
3. Model bazowy

Sieć **17-17-1**: jedna warstwa ukryta o szerokości równej liczbie cech, ReLU, α = 0,01, wagi N(0; 0,01), 30 000 epok. Oprócz wag końcowych zapamiętuję wagi z najniższym kosztem walidacyjnym (**early stopping**). Za „wyjście z plateau” przyjmuję pierwszą epokę, w której koszt treningowy spadł poniżej 0,6. Koszt stałej odpowiedzi (p = odsetek chorych dla każdego pacjenta) to 0,690.

```
wyjście z plateau (koszt < 0.6): epoka 724; najniższy koszt walidacyjny 0.393 w ep
oce 1783
```

	koszt train	koszt val	precision test	recall test	f1 test	accuracy test
wagi końcowe (30 000 epok)	0.031	0.909	0.786	0.786	0.786	0.803
early stopping (epoka 1783)	0.291	0.393	0.778	0.750	0.764	0.787

Rys. 1. Krzywa uczenia sieci 17-17-1 (α = 0,01, wagi N(0; 0,01))



Co widać:

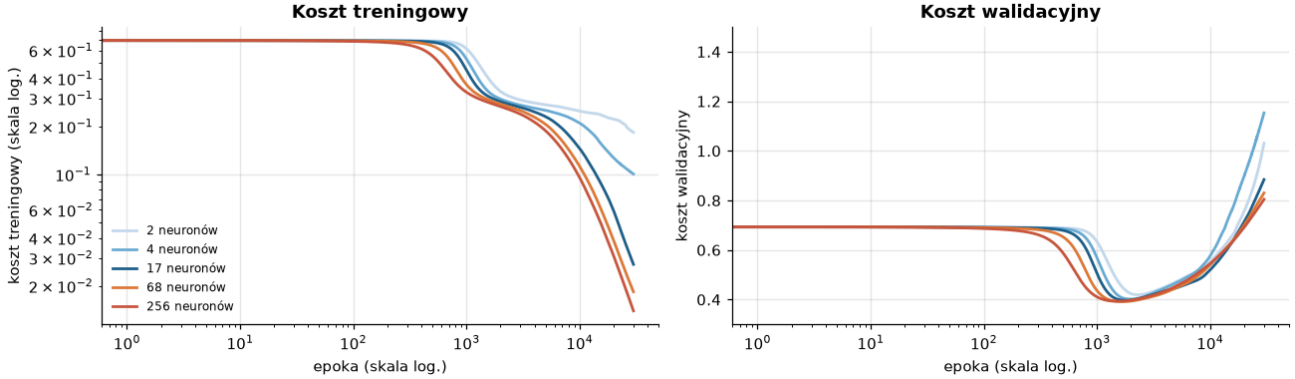
- przez pierwsze ok. **720 epok** koszt stoi na 0,69, a F1 = 0: wagi są tak małe, że sieć zwraca p ≈ 0,5 dla każdego pacjenta, a gradient jest bliski zera. To **plateau**, a nie minimum,
- potem koszt szybko spada, a najniższy koszt walidacyjny (0,393) jest w epoce **1783**. Na walidacji F1 = 0,84, na teście F1 = 0,764 (21 chorych wykrytych, 6 fałszywych alarmów, 7 pominiętych),
- dalej sieć **zapamiętuje** zbiór treningowy: po 30 000 epok koszt treningowy to 0,031 (accuracy 98%), a walidacyjny rośnie do 0,909, czyli ponad dwa razy więcej niż w minimum,
- F1 testowe po 30 000 epok (0,786) prawie się nie zmienia, bo F1 zależy tylko od strony progu 0,5. Koszt walidacyjny pokazuje jednak, że model jest coraz pewniejszy swoich błędów.

> **Wniosek:** w przeciwieństwie do regresji logistycznej sieć z warstwą ukrytą może dopasować się do danych treningowych prawie idealnie, więc warunek stopu (early stopping) jest konieczny. Przy tak małych wagach początkowych uczenie zaczyna się od długiego plateau.

4. Wymiarowość warstwy ukrytej

Jedna warstwa ukryta o szerokości **2 i 4** (znacznie mniej niż 17 cech), **17** (równo), **68 i 256** (znacznie więcej). Dla każdej szerokości 3 losowania wag i średnia.

Rys. 2. Szerokość warstwy ukrytej (średnia z 3 losowań wag)



neuronów	parametry	wyjście z plateau	koszt train po 30 000	min. koszt val	epoka min. val	koszt val po 30 000	F1 test (early stopping)	F1 test (po 30 000)
2	39.0	1055.0	0.1838	0.419	2274.0	1.031	0.756	0.702
4	77.0	880.0	0.1006	0.402	1973.0	1.153	0.764	0.773
17	324.0	766.0	0.0273	0.397	1811.0	0.884	0.764	0.771
68	1293.0	597.0	0.0184	0.392	1677.0	0.830	0.764	0.786
256	4865.0	428.0	0.0140	0.393	1518.0	0.804	0.764	0.793

Co widać:

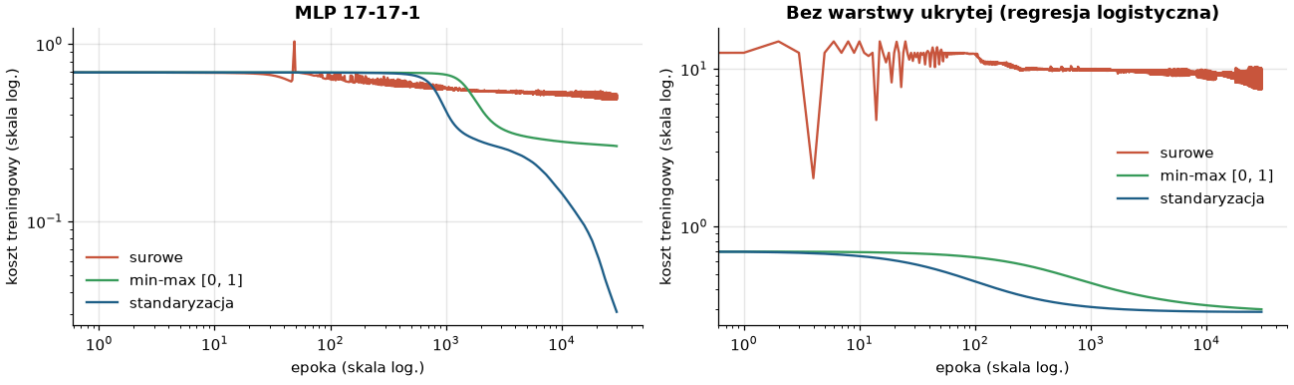
- im szersza warstwa, tym **krótsze plateau**: 1055 epok dla 2 neuronów, 766 dla 17, 428 dla 256. Gradient wag wyjściowych to suma po wszystkich neuronach ukrytych, więc przy większej liczbie neuronów sygnał jest silniejszy,
- wąska sieć (2 neurony) ma za małą pojemność, żeby zapamiętać trening: koszt końcowy 0,18. Szerokie sieci schodzą do 0,014–0,018,
- **najniższy koszt walidacyjny** jest prawie taki sam dla każdej szerokości (0,39–0,42), a F1 testowe przy early stopping wynosi ok. 0,76 dla każdej szerokości. Na 61 pacjentach jedna osoba zmienia F1 o ok. 0,02,
- po 30 000 epok wszystkie sieci są przeuczone (koszt walidacyjny 0,80–1,15).

> **Wniosek:** szerokość warstwy ukrytej wpływa na szybkość uczenia i na to, jak bardzo sieć może się przeuczyć, ale nie na jakość przy dobrym warunku stopu. Na tym małym zbiorze (181 pacjentów) najlepsza sieć nie jest lepsza od regresji logistycznej.

5. Dane znormalizowane i nieznormalizowane

Ta sama sieć 17-17-1 i, dla porównania, sieć bez warstwy ukrytej (regresja logistyczna) na danych surowych (cholesterol ok. 250, oldpeak ok. 1, cechy 0/1), przeskalowanych min-max do [0, 1] i standaryzowanych. α = 0,01 w każdym przypadku.

Rys. 3. Uczenie na danych surowych, min-max i standaryzowanych (α = 0,01)




```
wskaźnik uwarunkowania XᵀX: surowe 5.52e+06, min-max [0, 1] 2.50e+02, standaryzacj
a 4.58e+01
```

		koszt start	koszt po 30 000	min. koszt train	oscylacje (wzrosty w ost. 500 ep.)	min. koszt val	F1 test (early stopping)
surowe	**MLP 17-17-1**	0.693	0.519	0.488	250.0	0.646	0.667
	bez warstwy ukrytej	1.061	7.969	1.061	247.0	1.040	0.629
min-max [0, 1]	**MLP 17-17-1**	0.693	0.266	0.266	0.0	0.408	0.750
	bez warstwy ukrytej	0.694	0.298	0.298	0.0	0.390	0.772
standaryzacja	**MLP 17-17-1**	0.693	0.031	0.031	35.0	0.393	0.764
	bez warstwy ukrytej	0.696	0.287	0.287	0.0	0.387	0.764

Co widać:

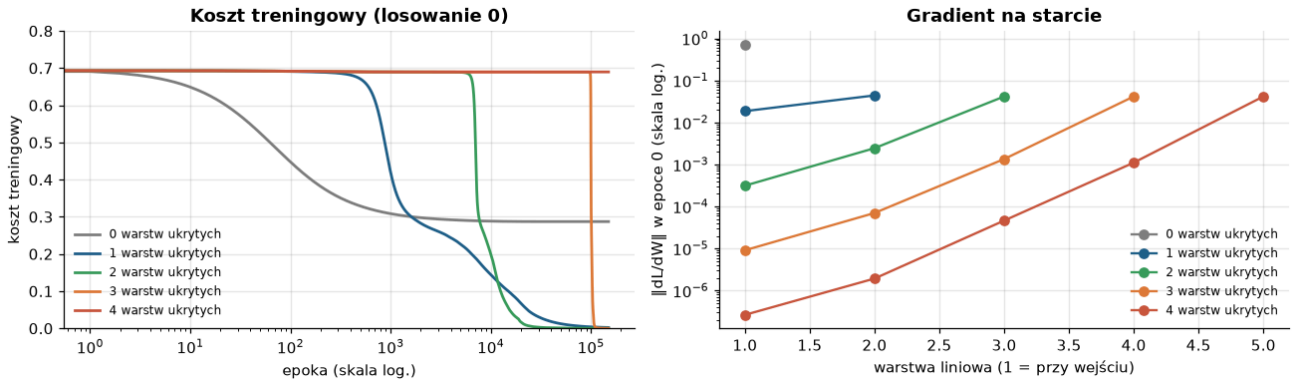
- wskaźnik uwarunkowania $X^T X$: surowe **5,5 mln**, min-max 250, standaryzacja 46,
- **surowe dane, regresja logistyczna:** α = 0,01 jest za duże dla kierunku cholesterolu (w ćw. 2 próg stabilności wynosił ok. $7 \cdot 10^{-5}$), więc koszt skacze i po 30 000 epok wynosi ok. 8, a F1 testowe 0,63,
- **surowe dane, MLP:** sieć nie rozbiega się (wagi N(0; 0,01) są małe, a ReLU obcina część sygnału), ale utyka na koszcie ok. 0,52 z oscylacjami, a F1 testowe to tylko 0,67,
- **min-max:** obie sieci się uczą, ale wolniej niż na standaryzowanych: MLP wychodzi z plateau dopiero po ok. 1400 epokach (standaryzacja: 724), a po 30 000 epok koszt to 0,27 zamiast 0,03,
- **standaryzacja:** najszybsze uczenie i najmniejszy koszt; F1 przy early stopping 0,75–0,77 dla min-max i standaryzacji.

> **Wniosek:** bez normalizacji przy α = 0,01 sieć się nie uczy, bo cechy o dużych wartościach dominują gradient i krok jest dla nich za długi, a dla cech 0/1 za krótki. Normalizacja (min-max albo standaryzacja) jest konieczna. Standaryzacja działa lepiej, bo daje cechom średnią 0 i podobną skalę.

6. Liczba warstw

Od 0 do 4 warstw ukrytych po 17 neuronów, α = 0,01, wagi N(0; 0,01), **150 000 epok**, 3 losowania. Po prawej norma gradientu każdej warstwy liniowej w pierwszej epoce.

Rys. 4. Liczba warstw ukrytych (po 17 neuronów, wagi N(0; 0,01), α = 0,01)



warstw ukrytych	wyjście z plateau (3 losowania)	koszt train po 150 000	min. koszt val	F1 test (early stopping)
0	23 / 21 / 21	0.2872	0.387	0.764
1	724 / 814 / 759	0.0018	0.397	0.764
2	6862 / 7368 / 8835	0.0002	0.399	0.764
3	99838 / 90854 / 93052	0.0002	0.418	0.75
4	— / — / —	0.6897	0.69	0.0

Co widać:

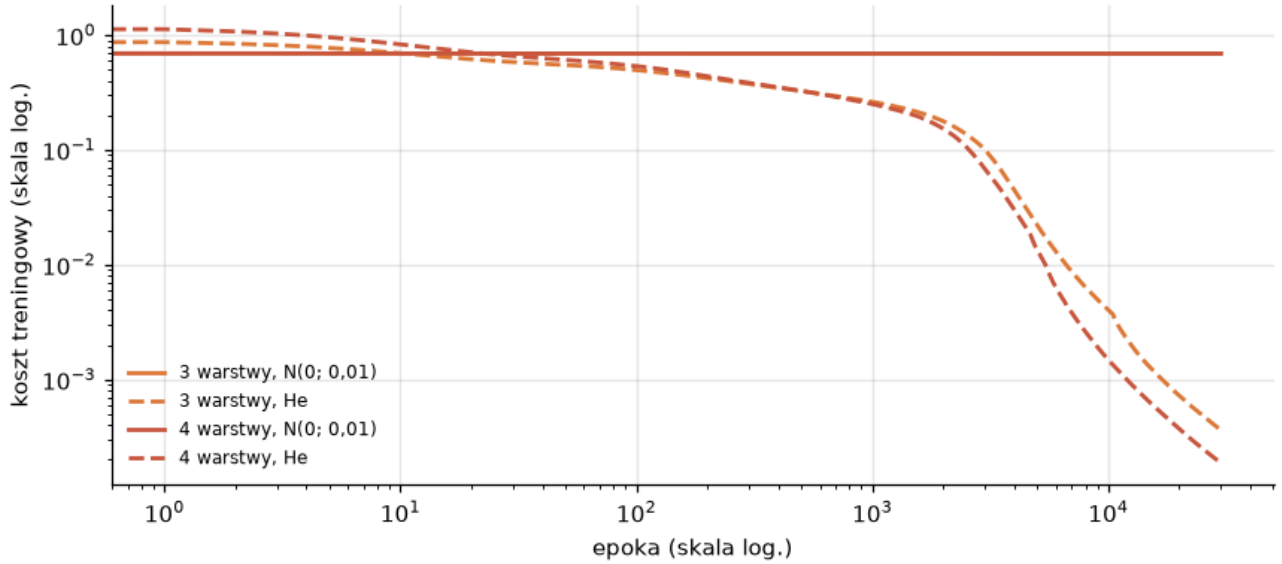
- każda dodatkowa warstwa wydłuża plateau ok. **10 razy**: wyjście po ok. 22 (0 warstw), 765 (1), 7700 (2) i 94 600 epokach (3 warstwy). Sieć z **4 warstwami** przez 150 000 epok w żadnym losowaniu nie zeszła z kosztu 0,690 (F1 = 0),
- prawy wykres pokazuje przyczynę: na starcie gradient **maleje kilka do kilkudziesięciu razy (ok. 7–37) z każdą warstwą** w stronę wejścia. Przy 4 warstwach gradient pierwszej warstwy to ok. $3 \cdot 10^{-7}$, więc przy α = 0,01 wagi praktycznie się nie zmieniają. To jest **zanikający gradient**: przy przejściu wstecz gradient jest mnożony przez macierze wag o elementach rzędu 0,01,
- sieci, które wyszły z plateau, uczą się potem bardzo szybko: koszt spada z 0,69 do prawie 0 w kilkaset epok (pionowe spadki na wykresie). Wyglądają podobnie na walidacji: najniższy koszt 0,39–0,42, F1 przy early stopping 0,75–0,76,
- więcej warstw nie poprawiło jakości: na tym zbiorze wystarcza regresja logistyczna (0 warstw).

> **Wniosek:** sieć z kilkoma warstwami może w zasadzie nauczyć się tego samego, ale przy inicjalizacji N(0; 0,01) i α = 0,01 głębsza sieć startuje z płaskiego obszaru funkcji kosztu (plateau / punkt siodłowy w okolicy w = 0). Czas wyjścia rośnie wykładniczo z liczbą warstw. To nie jest minimum lokalne: koszt 0,69 to koszt stałej odpowiedzi.

7. Dodatkowo: inicjalizacja He

Sprawdzenie, czy winna jest liczba warstw, czy inicjalizacja: te same sieci z 3 i 4 warstwami ukrytymi, ale wagi z $N\,(0;\,\sqrt{2/d_{in}})$ (He), która zachowuje wariancję sygnału przy ReLU. Pozostałe parametry bez zmian, 30 000 epok.

Rys. 5. Dodatkowo: te same sieci z inicjalizacją He



	wyjście z plateau	min. koszt val	epoka min. val	F1 test (early stopping)
3 warstwy, N(0; 0,01)	—	0.69	29972	0.0
3 warstwy, He	24.0	0.419	582.0	0.772
4 warstwy, N(0; 0,01)	—	0.69	1799	0.0
4 warstwy, He	55.0	0.463	709.0	0.772

Co widać: z inicjalizacją He sieci z 3 i 4 warstwami wychodzą z plateau po **24 i 55 epokach** zamiast po ok. 94 600 epokach albo wcale. Najniższy koszt walidacyjny (0,42 i 0,46) jest w epokach 582 i 709, a F1 testowe przy early stopping wynosi 0,772.

> **Wniosek:** problemem głębszych sieci w tym ćwiczeniu nie jest ich głębokość, tylko inicjalizacja zbyt małymi wagami. Ten temat rozwija druga część ćwiczenia.

8. Podsumowanie

czynnik	wpływ na uczenie	wpływ na jakość (F1 test, early stopping)	dowód
szerokość 2–4 (mniej niż 17 cech)	dłuższe plateau, mniejsza pojemność	ok. 0,76	Rys. 2
szerokość 17 (równo)	plateau ok. 770 epok	0,764	Rys. 1–2
szerokość 68–256 (dużo więcej)	krótsze plateau, szybsze przeuczenie	ok. 0,76	Rys. 2

czynnik	wpływ na uczenie	wpływ na jakość (F1 test, early stopping)	dowód
brak normalizacji	regresja logistyczna się rozbiega, MLP utyka na koszcie 0,52	0,63–0,67	Rys. 3
min-max / standaryzacja	uczenie działa, standaryzacja szybciej	0,75–0,77	Rys. 3
więcej warstw (N(0; 0,01))	plateau ok. 10 razy dłuższe na warstwę, 4 warstwy nie ruszają	bez poprawy, 0 dla 4 warstw	Rys. 4
inicjalizacja He	brak plateau także dla 3–4 warstw	0,772	Rys. 5

9. Wnioski

Propagacja wsteczna zaimplementowana jako sekwencja modułów z `forward` i `backward` daje gradienty zgodne z numerycznymi do ok. 10^{-10}, a sieć bez warstw ukrytych odtwarza regresję logistyczną z ćw. 2. Przy wagach N(0; 0,01) i $\alpha = 0{,}01$ każda sieć z warstwą ukrytą zaczyna od plateau na koszcie 0,69, bo małe wagi dają $p \approx 0{,}5$ i prawie zerowy gradient. Szerokość warstwy ukrytej zmienia głównie szybkość uczenia: szersza sieć szybciej opuszcza plateau i szybciej się przeucza, ale przy early stopping F1 testowe wynosi ok. 0,76 dla 2, 17 i 256 neuronów. Bez normalizacji danych sieć się nie uczy (koszt 0,52, F1 0,67), a regresja logistyczna wręcz się rozbiega, więc normalizacja, najlepiej standaryzacja, jest konieczna. Każda kolejna warstwa wydłuża plateau ok. dziesięciokrotnie, a sieć z czterema warstwami nie rusza w 150 000 epok, bo gradient maleje kilka do kilkudziesięciu razy na każdą warstwę w stronę wejścia. Inicjalizacja He usuwa ten problem, więc przyczyną jest zanikający gradient przy zbyt małych wagach, a nie sama głębokość. Na tak małym zbiorze żadna sieć wielowarstwowa nie była lepsza od regresji logistycznej, a wszystkie bez warunku stopu silnie się przeuczały.