Sieci neuronowe – ćwiczenie 3

Wielowarstwowa sieć neuronowa uczona propagacją wsteczną · zbiór Heart Disease (Cleveland)

Dawid Pilarski · nr albumu 280468

Kod przygotowany z pomocą narzędzia AI (Claude).

Najważniejsze wyniki

implementacja	moduły Linear, ReLU, sigmoida + entropia krzyżowa z *forward* i *backward*; gradient zgodny z numerycznym do ok. 10^{-10}
sieć 17-17-1 (α = 0,01, wagi N(0; 0,01))	przez ok. **720 epok** stoi na koszcie 0,69, potem się uczy; najlepsza na walidacji w epoce **1783**: test **F1 = 0,764**
przeuczenie	po 30 000 epok koszt treningowy 0,031, walidacyjny rośnie z 0,393 do **0,909**
szerokość warstwy ukrytej	2 → 256 neuronów: plateau krótsze (1055 → 428 epok), F1 przy early stopping ~0,76 dla każdej szerokości
normalizacja	dane surowe: regresja logistyczna się rozbiega, MLP utyka na koszcie 0,52 (F1 0,67); min-max i standaryzacja działają
liczba warstw	0 / 1 / 2 / 3 warstwy: wyjście z plateau po ok. 22 / 765 / 7700 / 94 600 epokach; **4 warstwy nie ruszają** w 150 000 epok
przyczyna	gradient maleje kilka do kilkudziesięciu razy na każdą warstwę w stronę wejścia; inicjalizacja He usuwa plateau (24–55 epok)

Spis treści: 1. Model bazowy · 2. Szerokość warstwy ukrytej · 3. Dane znormalizowane i nieznormalizowane · 4. Liczba warstw · 5. Dodatkowo: inicjalizacja He · 6. Podsumowanie · 7. Wnioski

🗣 CO MÓWIĘ

Na początek podsumowanie. Zbudowałem sieć wielowarstwową, w której każda operacja to moduł z forward i backward, i sprawdziłem, że gradienty zgadzają się z numerycznymi do 10^{-10}.

Przy wagach N(0; 0,01) i α = 0,01 sieć zaczyna od plateau na koszcie 0,69 i dopiero po ok. 720 epokach zaczyna się uczyć. Najlepszy wynik na teście to F1 = 0,76.

Badałem szerokość warstwy ukrytej, normalizację danych i liczbę warstw. Najważniejsze: każda kolejna warstwa wydłuża plateau ok. 10 razy, a 4 warstwy w ogóle nie ruszają. Inicjalizacja He to naprawia.

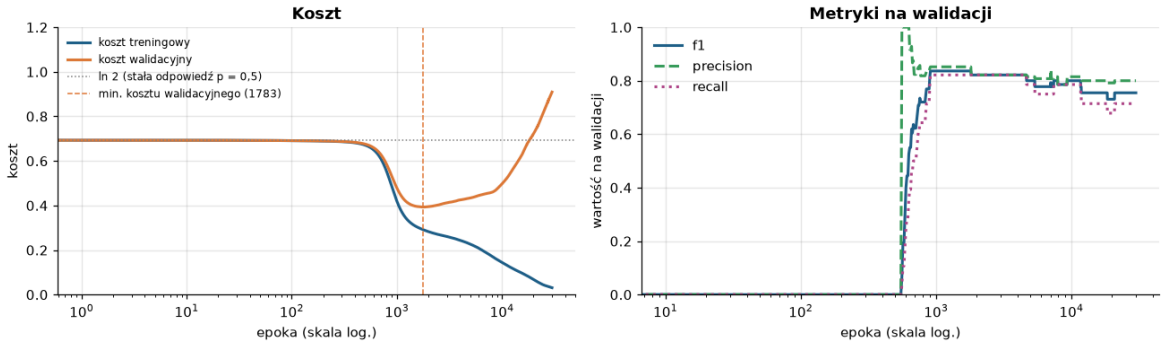
1. Model bazowy

Sieć **17-17-1**: jedna warstwa ukryta o szerokości równej liczbie cech, ReLU, α = 0,01, wagi N(0; 0,01), 30 000 epok. Oprócz wag końcowych zapamiętuję wagi z najniższym kosztem walidacyjnym (**early stopping**). Za „wyjście z plateau” przyjmuję pierwszą epokę, w której koszt treningowy spadł poniżej 0,6. Koszt stałej odpowiedzi (p = odsetek chorych dla każdego pacjenta) to 0,690.

> wyjście z plateau (koszt < 0.6): epoka 724; najniższy koszt walidacyjny 0.393 w epoce 1783

	koszt train	koszt val	precision test	recall test	f1 test	accuracy test
wagi końcowe (30 000 epok)	0,031	0,909	0,786	0,786	0,786	0,803
early stopping (epoka 1783)	0,291	0,393	0,778	0,750	0,764	0,787

Rys. 1. Krzywa uczenia sieci 17-17-1 (α = 0,01, wagi N(0; 0,01))



JAK CZYTAĆ RYS. 1

po lewej koszt w kolejnych epokach (oś x logarytmiczna: $10^2 = 100$, $10^3 = 1000$, $10^4 = 10\,000$). Niebieska linia to koszt treningowy, pomarańczowa walidacyjny, szara kropkowana to ln 2 = 0,693, czyli koszt sieci, która każdemu daje 50%. Pionowa przerywana linia to epoka z najniższym kosztem walidacyjnym. Po prawej F1, precision i recall na walidacji.

OBSERWACJE

- przez pierwsze ok. **720 epok** koszt stoi na 0,69, a F1 = 0: wagi są tak małe, że sieć zwraca p ≈ 0,5 dla każdego pacjenta, a gradient jest bliski zera. To **plateau**, a nie minimum,
- potem koszt szybko spada, a najniższy koszt walidacyjny (0,393) jest w epoce **1783**. Na walidacji F1 = 0,84, na teście F1 = 0,764 (21 chorych wykrytych, 6 fałszywych alarmów, 7 pominiętych),
- dalej sieć **zapamiętuje** zbiór treningowy: po 30 000 epok koszt treningowy to 0,031 (accuracy 98%), a walidacyjny rośnie do 0,909, czyli ponad dwa razy więcej niż w minimum,
- F1 testowe po 30 000 epok (0,786) prawie się nie zmienia, bo F1 zależy tylko od strony progu 0,5. Koszt walidacyjny pokazuje jednak, że model jest coraz pewniejszy swoich błędów.

WNIOSEK

w przeciwieństwie do regresji logistycznej sieć z warstwą ukrytą może dopasować się do danych treningowych prawie idealnie, więc warunek stopu (early stopping) jest konieczny. Przy tak małych wagach początkowych uczenie zaczyna się od długiego plateau.

🗣 CO MÓWIĘ

To sieć 17-17-1 z parametrami z treści. Oś x jest logarytmiczna.

Przez pierwsze ok. 720 epok koszt stoi na 0,69, a F1 jest zero. Wagi są tak małe, że sieć każdemu mówi 50%, a gradient jest prawie zerowy. To plateau, a nie minimum.

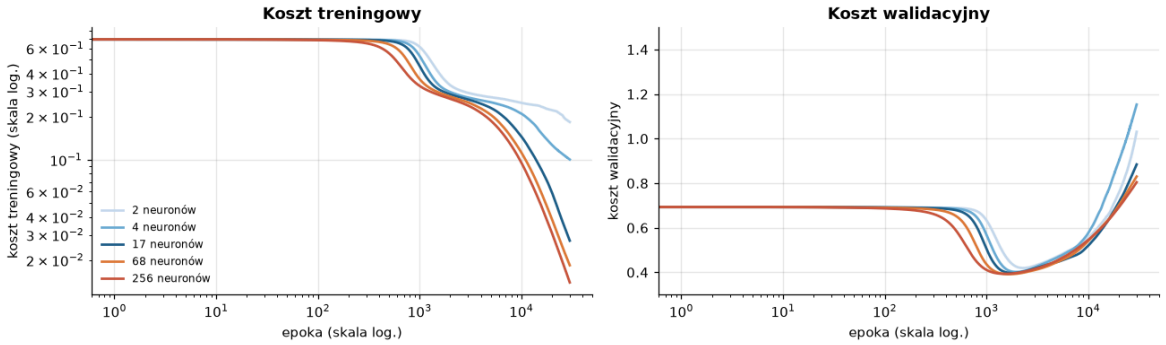
Potem sieć szybko się uczy. Najniższy koszt walidacyjny jest w epoce 1783 i wtedy F1 na teście to 0,76.

Dalej sieć zapamiętuje zbiór treningowy: koszt treningowy spada do 0,03, a walidacyjny rośnie do 0,91. Dlatego biorę wagi z najlepszej epoki, czyli early stopping.

2. Wymiarowość warstwy ukrytej

Jedna warstwa ukryta o szerokości **2 i 4** (znacznie mniej niż 17 cech), **17** (równo), **68 i 256** (znacznie więcej). Dla każdej szerokości 3 losowania wag i średnia.

Rys. 2. Szerokość warstwy ukrytej (średnia z 3 losowań wag)



neuronów	parametry	wyjście z plateau	koszt train po 30 000	min. koszt val	epoka min. val	koszt val po 30 000	F1 test (early stopping)	F1 test (po 30 000)
2	39	1055	0,1838	0,419	2274	1,031	0,756	0,702
4	77	880	0,1006	0,402	1973	1,153	0,764	0,773
17	324	766	0,0273	0,397	1811	0,884	0,764	0,771
68	1293	597	0,0184	0,392	1677	0,830	0,764	0,786
256	4865	428	0,0140	0,393	1518	0,804	0,764	0,793

JAK CZYTAĆ RYS. 2

każda linia to średnia z 3 losowań wag dla jednej szerokości warstwy ukrytej. Jasnoniebieskie to wąskie warstwy (2 i 4 neurony), ciemnoniebieska 17 (tyle co cech), pomarańczowa i czerwona szerokie (68 i 256). Po lewej koszt treningowy (obie osie logarytmiczne), po prawej walidacyjny.

OBSERWACJE

- im szersza warstwa, tym **krótsze plateau**: 1055 epok dla 2 neuronów, 766 dla 17, 428 dla 256. Gradient wag wyjściowych to suma po wszystkich neuronach ukrytych, więc przy większej liczbie neuronów sygnał jest silniejszy,
- wąska sieć (2 neurony) ma za małą pojemność, żeby zapamiętać trening: koszt końcowy 0,18. Szerokie sieci schodzą do 0,014–0,018,
- **najniższy koszt walidacyjny** jest prawie taki sam dla każdej szerokości (0,39–0,42), a F1 testowe przy early stopping wynosi ok. 0,76 dla każdej szerokości. Na 61 pacjentach jedna osoba zmienia F1 o ok. 0,02,
- po 30 000 epok wszystkie sieci są przeuczone (koszt walidacyjny 0,80–1,15).

WNIOSEK

szerokość warstwy ukrytej wpływa na szybkość uczenia i na to, jak bardzo sieć może się przeuczyć, ale nie na jakość przy dobrym warunku stopu. Na tym małym zbiorze (181 pacjentów) najlepsza sieć nie jest lepsza od regresji logistycznej.

🗣 CO MÓWIĘ

Szerokość warstwy ukrytej: 2 i 4 neurony to znacznie mniej niż cech, 17 to tyle samo, 68 i 256 znacznie więcej.

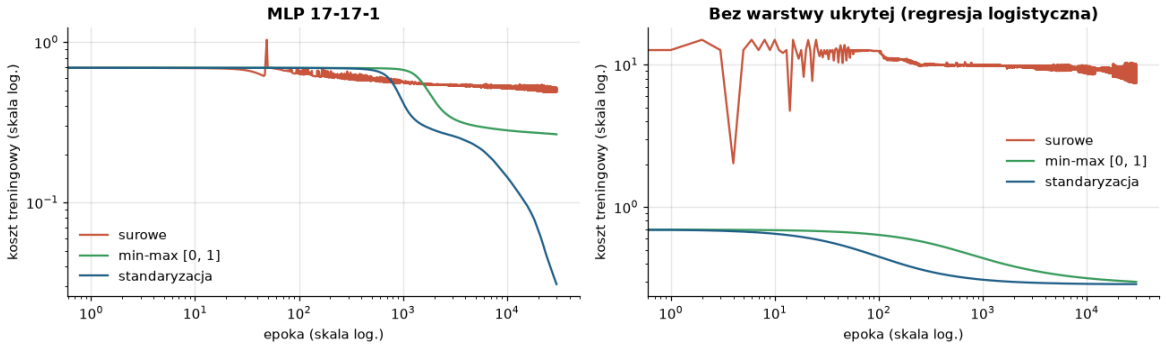
Szersza sieć szybciej wychodzi z plateau, z 1055 epok dla 2 neuronów do 428 dla 256, i szybciej się przeucza. Wąska sieć, 2 neurony, nie ma pojemności i koszt zostaje na 0,18.

Ale przy early stopping F1 na teście wychodzi ok. 0,76 dla każdej szerokości. Czyli szerokość zmienia szybkość i przeuczenie, a nie jakość.

3. Dane znormalizowane i nieznormalizowane

Ta sama sieć 17-17-1 i, dla porównania, sieć bez warstwy ukrytej (regresja logistyczna) na danych surowych (cholesterol ok. 250, oldpeak ok. 1, cechy 0/1), przeskalowanych min-max do [0, 1] i standaryzowanych. α = 0,01 w każdym przypadku.

Rys. 3. Uczenie na danych surowych, min-max i standaryzowanych (α = 0,01)



wskaźnik uwarunkowania X^TX: surowe $5{,}52 \cdot 10^6$, min-max [0, 1] $2{,}50 \cdot 10^2$, standaryzacja $4{,}58 \cdot 10^1$

		koszt start	koszt po 30 000	min. koszt train	oscylacje (wzrosty w ost. 500 ep.)	min. koszt val	F1 test (early stopping)
surowe	**MLP 17-17-1**	0,693	0,519	0,488	250	0,646	0,667
	bez warstwy ukrytej	1,061	7,969	1,061	247	1,040	0,629
min-max [0, 1]	**MLP 17-17-1**	0,693	0,266	0,266	0	0,408	0,750
	bez warstwy ukrytej	0,694	0,298	0,298	0	0,390	0,772
standaryzacja	**MLP 17-17-1**	0,693	0,031	0,031	35	0,393	0,764
	bez warstwy ukrytej	0,696	0,287	0,287	0	0,387	0,764

JAK CZYTAĆ RYS. 3

po lewej sieć 17-17-1, po prawej dla porównania sieć bez warstwy ukrytej (regresja logistyczna). Czerwona linia to dane surowe, zielona min-max, niebieska standaryzowane. Obie osie logarytmiczne.

OBSERWACJE

- wskaźnik uwarunkowania X^TX: surowe **5,5 mln**, min-max 250, standaryzacja 46,
- **surowe dane, regresja logistyczna:** α = 0,01 jest za duże dla kierunku cholesterolu (w ćw. 2 próg stabilności wynosił ok. $7 \cdot 10^{-5}$), więc koszt skacze i po 30 000 epok wynosi ok. 8, a F1 testowe 0,63,
- **surowe dane, MLP:** sieć nie rozbiega się (wagi N(0; 0,01) są małe, a ReLU obcina część sygnału), ale utyka na koszcie ok. 0,52 z oscylacjami, a F1 testowe to tylko 0,67,
- **min-max:** obie sieci się uczą, ale wolniej niż na standaryzowanych: MLP wychodzi z plateau dopiero po ok. 1400 epokach (standaryzacja: 724), a po 30 000 epok koszt to 0,27 zamiast 0,03,
- **standaryzacja:** najszybsze uczenie i najmniejszy koszt; F1 przy early stopping 0,75–0,77 dla min-max i standaryzacji.

WNIOSEK

bez normalizacji przy α = 0,01 sieć się nie uczy, bo cechy o dużych wartościach dominują gradient i krok jest dla nich za długi, a dla cech 0/1 za krótki. Normalizacja (min-max albo standaryzacja) jest konieczna. Standaryzacja działa lepiej, bo daje cechom średnią 0 i podobną skalę.

🗣 CO MÓWIĘ

Normalizacja. Na surowych danych cholesterol ma ok. 250, a cechy 0/1 jedynkę, więc jedno α nie pasuje do wszystkich kierunków. Uwarunkowanie rośnie z 46 do 5,5 miliona.

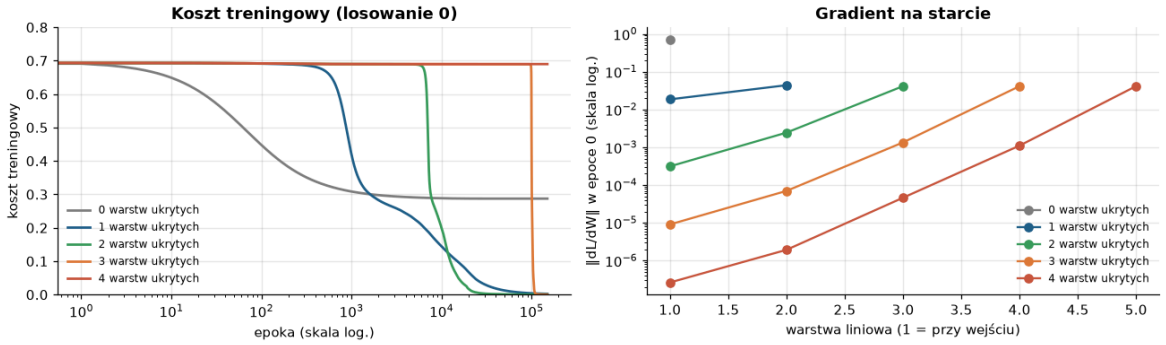
Regresja logistyczna na surowych danych się rozbiega, a sieć utyka na koszcie 0,52 i ma F1 0,67.

Min-max i standaryzacja działają, standaryzacja szybciej. Czyli normalizacja jest konieczna.

4. Liczba warstw

Od 0 do 4 warstw ukrytych po 17 neuronów, α = 0,01, wagi N(0; 0,01), **150 000 epok**, 3 losowania. Po prawej norma gradientu każdej warstwy liniowej w pierwszej epoce.

Rys. 4. Liczba warstw ukrytych (po 17 neuronów, wagi N(0; 0,01), α = 0,01)



warstw ukrytych	wyjście z plateau (3 losowania)	koszt train po 150 000	min. koszt val	F1 test (early stopping)
0	23 / 21 / 21	0,2872	0,387	0,764
1	724 / 814 / 759	0,0018	0,397	0,764
2	6862 / 7368 / 8835	0,0002	0,399	0,764
3	99838 / 90854 / 93052	0,0002	0,418	0,75
4	— / — / —	0,6897	0,69	0

JAK CZYTAĆ RYS. 4

po lewej koszt treningowy dla 0–4 warstw ukrytych (losowanie 0, oś x logarytmiczna). Linia pozioma na 0,69 to plateau, pionowy spadek to moment, w którym sieć „ruszyła”. Po prawej wielkość gradientu każdej warstwy liniowej w pierwszej epoce: warstwa 1 jest przy wejściu, ostatnia przy wyjściu (oś y logarytmiczna).

OBSERWACJE

- każda dodatkowa warstwa wydłuża plateau ok. **10 razy**: wyjście po ok. 22 (0 warstw), 765 (1), 7700 (2) i 94 600 epokach (3 warstwy). Sieć z **4 warstwami** przez 150 000 epok w żadnym losowaniu nie zeszła z kosztu 0,690 (F1 = 0),
- prawy wykres pokazuje przyczynę: na starcie gradient **maleje kilka do kilkudziesięciu razy (ok. 7–37) z każdą warstwą** w stronę wejścia. Przy 4 warstwach gradient pierwszej warstwy to ok. $3 \cdot 10^{-7}$, więc przy α = 0,01 wagi praktycznie się nie zmieniają. To jest **zanikający gradient**: przy przejściu wstecz gradient jest mnożony przez macierze wag o elementach rzędu 0,01,
- sieci, które wyszły z plateau, uczą się potem bardzo szybko: koszt spada z 0,69 do prawie 0 w kilkaset epok (pionowe spadki na wykresie). Wyglądają podobnie na walidacji: najniższy koszt 0,39–0,42, F1 przy early stopping 0,75–0,76,
- więcej warstw nie poprawiło jakości: na tym zbiorze wystarcza regresja logistyczna (0 warstw).

WNIOSEK

sieć z kilkoma warstwami może w zasadzie nauczyć się tego samego, ale przy inicjalizacji N(0; 0,01) i α = 0,01 głębsza sieć startuje z płaskiego obszaru funkcji kosztu (plateau / punkt siodłowy w okolicy w = 0). Czas wyjścia rośnie wykładniczo z liczbą warstw. To nie jest minimum lokalne: koszt 0,69 to koszt stałej odpowiedzi.

🗣 CO MÓWIĘ

Liczba warstw ukrytych od 0 do 4, po 17 neuronów.

Na lewym wykresie każda kolejna warstwa wydłuża plateau ok. 10 razy: 22, 765, 7700 i 94 600 epok. Cztery warstwy nie ruszyły przez 150 000 epok.

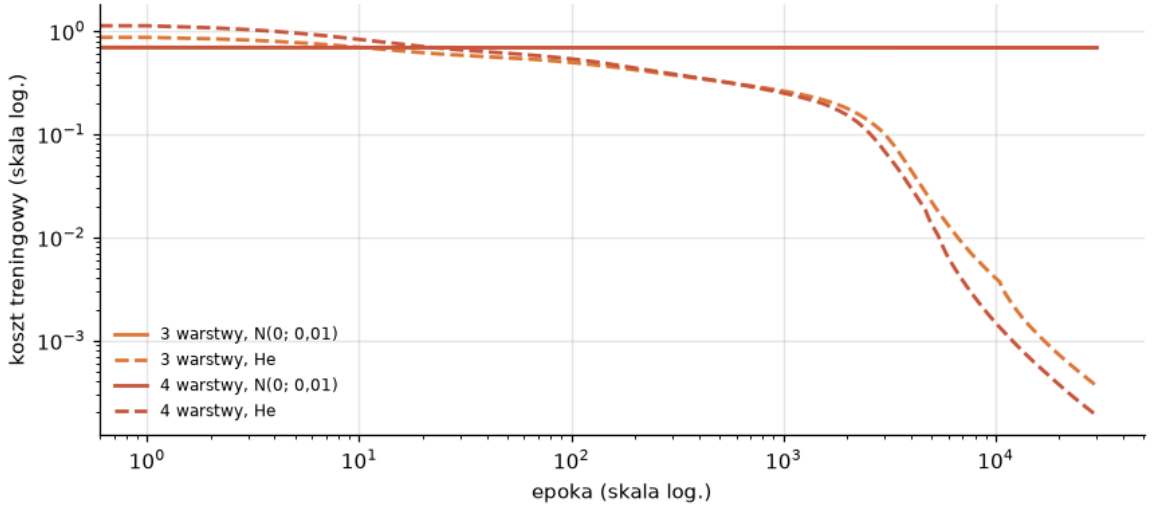
Prawy wykres pokazuje dlaczego: gradient maleje kilka do kilkudziesięciu razy z każdą warstwą w stronę wejścia. Przy 4 warstwach gradient pierwszej warstwy to $3 \cdot 10^{-7}$. To zanikający gradient.

Głębsze sieci, które ruszyły, nie są lepsze: F1 ok. 0,75–0,76.

5. Dodatkowo: inicjalizacja He

Sprawdzenie, czy winna jest liczba warstw, czy inicjalizacja: te same sieci z 3 i 4 warstwami ukrytymi, ale wagi z $N\left(0; \sqrt{2/d_{in}}\right)$ (He), która zachowuje wariancję sygnału przy ReLU. Pozostałe parametry bez zmian, 30 000 epok.

Rys. 5. Dodatkowo: te same sieci z inicjalizacją He



	wyjście z plateau	min. koszt val	epoka min. val	F1 test (early stopping)
3 warstwy, N(0; 0,01)	—	0,69	29 972	0
3 warstwy, He	24	0,419	582	0,772
4 warstwy, N(0; 0,01)	—	0,69	1799	0
4 warstwy, He	55	0,463	709	0,772

JAK CZYTAĆ RYS. 5

linie ciągłe to wagi N(0; 0,01) jak w treści, przerywane to inicjalizacja He. Pomarańczowe: 3 warstwy ukryte, czerwone: 4. Obie osie logarytmiczne.

OBSERWACJE

z inicjalizacją He sieci z 3 i 4 warstwami wychodzą z plateau po **24 i 55 epokach** zamiast po ok. 94 600 epokach albo wcale. Najniższy koszt walidacyjny (0,42 i 0,46) jest w epokach 582 i 709, a F1 testowe przy early stopping wynosi 0,772.

WNIOSEK

problemem głębszych sieci w tym ćwiczeniu nie jest ich głębokość, tylko inicjalizacja zbyt małymi wagami. Ten temat rozwija druga część ćwiczenia.

🗣 CO MÓWIĘ

Sprawdziłem jeszcze, czy winna jest głębokość, czy inicjalizacja. Te same 3 i 4 warstwy z inicjalizacją He uczą się od razu, po 24 i 55 epokach.

Czyli problemem są za małe wagi startowe, a nie sama liczba warstw. To prowadzi do drugiej części ćwiczenia.

6. Podsumowanie

czynnik	wpływ na uczenie	wpływ na jakość (F1 test, early stopping)	dowód
szerokość 2–4 (mniej niż 17 cech)	dłuższe plateau, mniejsza pojemność	ok. 0,76	Rys. 2
szerokość 17 (równo)	plateau ok. 770 epok	0,764	Rys. 1–2
szerokość 68–256 (dużo więcej)	krótsze plateau, szybsze przeuczenie	ok. 0,76	Rys. 2
brak normalizacji	regresja logistyczna się rozbiega, MLP utyka na koszcie 0,52	0,63–0,67	Rys. 3
min-max / standaryzacja	uczenie działa, standaryzacja szybciej	0,75–0,77	Rys. 3
więcej warstw (N(0; 0,01))	plateau ok. 10 razy dłuższe na warstwę, 4 warstwy nie ruszają	bez poprawy, 0 dla 4 warstw	Rys. 4
inicjalizacja He	brak plateau także dla 3–4 warstw	0,772	Rys. 5

🗣 CO MÓWIĘ

W tabeli jest wszystko razem. Szerokość zmienia szybkość i przeuczenie, normalizacja jest konieczna, a dodatkowe warstwy przy wagach 0,01 wydłużają plateau wykładniczo.

7. Wnioski

Propagacja wsteczna zaimplementowana jako sekwencja modułów z *forward* i *backward* daje gradienty zgodne z numerycznymi do ok. 10^{-10}, a sieć bez warstw ukrytych odtwarza regresję logistyczną z ćw. 2. Przy wagach N(0; 0,01) i $\alpha = 0{,}01$ każda sieć z warstwą ukrytą zaczyna od plateau na koszcie 0,69, bo małe wagi dają $p \approx 0{,}5$ i prawie zerowy gradient. Szerokość warstwy ukrytej zmienia głównie szybkość uczenia: szersza sieć szybciej opuszcza plateau i szybciej się przeucza, ale przy early stopping F1 testowe wynosi ok. 0,76 dla 2, 17 i 256 neuronów. Bez normalizacji danych sieć się nie uczy (koszt 0,52, F1 0,67), a regresja logistyczna wręcz się rozbiega, więc normalizacja, najlepiej standaryzacja, jest konieczna. Każda kolejna warstwa wydłuża plateau ok. dziesięciokrotnie, a sieć z czterema warstwami nie rusza w 150 000 epok, bo gradient maleje kilka do kilkudziesięciu razy na każdą warstwę w stronę wejścia. Inicjalizacja He usuwa ten problem, więc przyczyną jest zanikający gradient przy zbyt małych wagach, a nie sama głębokość. Na tak małym zbiorze żadna sieć wielowarstwowa nie była lepsza od regresji logistycznej, a wszystkie bez warunku stopu silnie się przeuczały.

🗣 CO MÓWIĘ

Tu czytam swoje wnioski. Jeśli mam powiedzieć jedno zdanie: implementacja działa, ale przy wagach N(0; 0,01) głębsza sieć startuje z płaskowyżu, z którego zwykły gradient wychodzi tym dłużej, im więcej ma warstw.