Jak to liczyć – zeszyt ćwiczeń (ćw. 3 + wykłady 3–4)

Cel: umieć policzyć na kartce wszystko, co może być na wyjściówce: przejście w przód, stratę, δ, gradienty wag, biasów i wejść, krok uczenia, ADAM i He. Każdy rozdział ma: **przepis** (co robisz po kolei), **przykład rozwiązany** i **zadania**. Pełne rozwiązania są na końcu (rozdz. R).

> **Jedno zdanie, z którego wynika cały backward:** gradient rzeczy = „jeśli ruszę tę liczbę o 1, o ile ruszy się L”. Dla wagi: δ **jej neuronu × jej wejście** x. Dla biasu: δ. Dla wejścia x: **suma po neuronach:** δ **neuronu × waga przy tym** x.

Spis

rozdz.	co liczysz
1	macierz × wektor, transpozycja, $\odot$, tabliczka δx^T
2	pochodne, których potrzebujesz (sigmoida, ReLU, ln)
3	reguła łańcuchowa: jedna droga, dwie drogi
4	przejście w przód warstwy: $z = Wx + b$, $a = \mathrm{ReLU}(z)$
5	wyjście: sigmoida + BCE, softmax + entropia krzyżowa, δ na wyjściu
6	backward przez ReLU (maska)
7	backward przez warstwę liniową: dW, db, dx
8	krok uczenia $W - \alpha\, dW$
9	cała sieć 2 → 2 → 1: przód, tył, nowe wagi
10	jakobian: tabelka i „w dół kolumny”
11	kształty macierzy
12	paczki, ADAM, inicjalizacja He
13	notacja z wykładu ($\delta = y - \hat{y}$, plus w kroku)
R	rozwiązania

1. Rachunki na macierzach

działanie	przepis	przykład
macierz × wektor Wx	każdy **wiersz** W mnożysz z x element po elemencie i dodajesz; wynik ma tyle liczb, ile W ma wierszy	$\begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 2-1 \\ -1-3 \end{bmatrix} = \begin{bmatrix} 1 \\ -4 \end{bmatrix}$
transpozycja W^T	kolumny stają się wierszami (kolumna 1 → wiersz 1)	$\begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix}^T = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix}$
$\odot$ (element-wise)	mnożysz liczby z tego samego miejsca	$[1,2,3] \odot [4,5,6] = [4,10,18]$

tabliczka δx^T	δ pionowo z lewej, x poziomo u góry, w kratce iloczyn; wynik: tyle wierszy, ile δ, tyle kolumn, ile x	$\delta = [2, 1]$, $x = [1, 2]$: $\begin{bmatrix} 2 \cdot 1 & 2 \cdot 2 \\ 1 \cdot 1 & 1 \cdot 2 \end{bmatrix} = \begin{bmatrix} 2 & 4 \\ 1 & 2 \end{bmatrix}$

Zadania 1:

a) $W = \begin{bmatrix} 1 & 2 \\ 0 & -1 \end{bmatrix}$, $x = [3, 1]$. Policz Wx.

b) Transponuj $\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$. Jaki kształt ma wynik?

c) $[2, -1, 3] \odot [4, 5, 0]$

d) Tabliczka δx^T dla $\delta = [1, -2]$, $x = [3, 0, 2]$.

2. Pochodne, których potrzebujesz

funkcja	pochodna	jak liczyć szybko
$c \cdot x$	c	liczba stojąca przy x
x^2	$2x$	dla $x = 3$: 6
$\ln p$	$\frac{1}{p}$	dla $p = 0{,}25$: 4
$\sigma(z) = \frac{1}{1+e^{-z}}$	$a(1-a)$, gdzie $a = \sigma(z)$	najpierw policz a, potem $a \cdot (1-a)$. Maks. 0,25 przy $z = 0$
$\mathrm{ReLU}(z) = \max(0, z)$	1 gdy $z > 0$, 0 gdy $z \leq 0$	**nie** wartość ReLU, tylko 0 albo 1
$\tanh(z)$	$1 - \tanh^2(z)$	dla $\tanh = 0{,}5$: $1 - 0{,}25 = 0{,}75$

Pułapka: $\mathrm{ReLU}(2) = 2$, ale pochodna ReLU w $z = 2$ to **1**. Wstecz zawsze mnożysz przez pochodną, nie przez wartość.

Zadania 2:

a) $\sigma(z) = 0{,}8$. Ile wynosi $\sigma'(z)$?

b) $z = 0$. Ile wynosi $\sigma(z)$ i $\sigma'(z)$?

c) Pochodna ReLU dla $z = -3$, $z = 0{,}1$, $z = 100$.

d) Pochodna $-\ln p$ dla $p = 0{,}25$.

3. Reguła łańcuchowa

krok	co robisz
1	policz wszystko w przód (wartości w każdym ogniwie)
2	dla każdego ogniwa osobno policz pochodną „wyjście ogniwa po wejściu ogniwa”
3	jedna droga: **pomnóż** pochodne ogniw
4	kilka dróg (zmienna wpływa na L na kilka sposobów): policz każdą drogę osobno i **dodaj**

Przykład rozwiązany: $w \to z \to L$, $z = 3w$, $L = z^2$, $w = 1$.

1. przód: $z = 3$, $L = 9$
2. ogniwa: $\frac{\partial L}{\partial z} = 2z = 6$, $\frac{\partial z}{\partial w} = 3$
3. $\frac{\partial L}{\partial w} = 6 \cdot 3 = 18$

Zadania 3:

a) $z = 2w + 1$, $L = z^2$, $w = 1$. Policz z, L, $\frac{\partial L}{\partial z}$, $\frac{\partial z}{\partial w}$, $\frac{\partial L}{\partial w}$.

b) Dwie drogi: $a = 3x$, $b = x^2$, $L = a + b$, $x = 2$. Policz $\frac{\partial L}{\partial x}$ jako sumę dróg przez a i przez b.

4. Przejście w przód jednej warstwy

krok	wzór	co robisz
1	$z = Wx + b$	wiersz W razy x, plus bias (rozdz. 1)
2	$a = \mathrm{ReLU}(z)$	każdy element: ujemny lub 0 → 0, dodatni zostaje
3	zapamiętaj x i z	x potrzebne do dW, z do maski ReLU

Przykład rozwiązany: $x = [1, -1]$, $W = \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix}$, $b = [0, 0]$.

1. $z_1 = 2 \cdot 1 + 1 \cdot (-1) + 0 = 1$; $z_2 = -1 \cdot 1 + 3 \cdot (-1) + 0 = -4$
2. $a = [\max(0, 1), \max(0, -4)] = [1, 0]$

Zadania 4:

a) $x = [2, -1]$, $W = \begin{bmatrix} 1 & 1 \\ -2 & 1 \end{bmatrix}$, $b = [0, 1]$. Policz z i a.

b) $x = [1, 1]$, $W = \begin{bmatrix} 2 & -3 \\ 1 & 1 \end{bmatrix}$, $b = [-1, 0]$. Policz z i a.

5. Wyjście sieci i δ na wyjściu

wariant	przód	strata	δ na wyjściu
sigmoida + BCE (ćw. 2, ćw. 3)	$p = \sigma(z)$	chory ($y = 1$): $L = -\ln p$; zdrowy ($y = 0$): $L = -\ln(1 - p)$	$\delta = p - y$
softmax + entropia krzyżowa (wykład 3)	$\hat{y}_k = \frac{e^{z_k}}{\sum_j e^{z_j}}$	$L = -\ln \hat{y}_{\text{prawdziwej klasy}}$	$\delta_k = \hat{y}_k - y_k$

Po ludzku: δ na wyjściu to zawsze „ile sieć powiedziała minus ile powinna”. Za dużo → $\delta > 0$, za mało → $\delta < 0$. Z tego zaczyna się cały backward.

Przykład rozwiązany (sigmoida): $z = 1$, $y = 0$.

1. $p = \sigma(1) = \frac{1}{1+e^{-1}} = \frac{1}{1{,}368} = 0{,}731$

2. $y = 0$, więc $L = -\ln(1 - 0{,}731) = -\ln 0{,}269 = 1{,}313$
3. $\delta = p - y = 0{,}731 - 0 = 0{,}731$

Przykład rozwiązany (softmax): $z = [3, 1, -3]$, prawdziwa klasa 1, czyli $y = [1, 0, 0]$.

1. $e^3 = 20{,}09$, $e^1 = 2{,}72$, $e^{-3} = 0{,}05$; suma $22{,}85$
2. $\hat{y} = [0{,}879;\ 0{,}119;\ 0{,}002]$
3. $L = -\ln 0{,}879 = 0{,}129$
4. $\delta = \hat{y} - y = [0{,}879 - 1;\ 0{,}119;\ 0{,}002] = [-0{,}121;\ 0{,}119;\ 0{,}002]$

Zadania 5:

a) Sigmoida: $z = 0$, $y = 1$. Policz p, L, δ.

b) Sigmoida: $z = 2$, $y = 0$. Policz p, L, δ. (Masz: $e^{-2} = 0{,}135$.)

c) Softmax: $z = [1, 1, 0]$, prawdziwa klasa 3. Policz $\hat{y}$, L, δ. (Masz: $e = 2{,}718$.)

6. Backward przez ReLU (maska)

krok	co robisz
1	weź zapamiętane z przodu z
2	maska: 1 tam, gdzie $z > 0$; 0 tam, gdzie $z \leq 0$
3	$\frac{\partial L}{\partial z} = \frac{\partial L}{\partial a} \odot \text{maska}$ (to, co przyszło z góry, razy maska, element po elemencie)

Przykład rozwiązany: $z = [-1, 2, 0{,}5]$, z góry $\frac{\partial L}{\partial a} = [3, 1, 4]$.

1. maska $= [0, 1, 1]$
2. $\frac{\partial L}{\partial z} = [3 \cdot 0, 1 \cdot 1, 4 \cdot 1] = [0, 1, 4]$

Zadania 6:

a) $z = [3, -1, 0, 2]$, z góry $[1, 2, 3, 4]$. Maska i $\frac{\partial L}{\partial z}$?

b) $z = [-5, -0{,}1]$, z góry $[7, 9]$. Co się dzieje z gradientem i dlaczego?

7. Backward przez warstwę liniową: dW, db, dx

$$dW = \delta\, x^T, \qquad db = \delta, \qquad dx = W^T \delta$$

co	przepis	skąd biorę	co z tym robię
dW	tabliczka: δ z lewej, x u góry, w kratce iloczyn. W **nie występuje!**	δ z góry, x zapamiętane z przodu	zostaje w warstwie (zmiana wag)
db	przepisz δ	δ z góry	zostaje w warstwie

dx	dla każdego x_j: weź **kolumnę** j macierzy W, pomnóż z δ element po elemencie i dodaj. Wynik ma tyle liczb, ile jest x	W (obecne wagi), δ z góry	oddajesz w dół (warstwa niżej dostaje to „z góry”)

Przykład rozwiązany: $x = [1, 2]$, $W = \begin{bmatrix} 1 & 0 \\ 3 & -1 \end{bmatrix}$, $\delta = [2, 1]$.

1. dW: wiersz $\delta_1 = 2$: $[2 \cdot 1, 2 \cdot 2] = [2, 4]$; wiersz $\delta_2 = 1$: $[1 \cdot 1, 1 \cdot 2] = [1, 2]$ → $dW = \begin{bmatrix} 2 & 4 \\ 1 & 2 \end{bmatrix}$
2. $db = [2, 1]$
3. dx_1: kolumna 1 W to $[1, 3]$: $1 \cdot 2 + 3 \cdot 1 = 5$; dx_2: kolumna 2 to $[0, -1]$: $0 \cdot 2 + (-1) \cdot 1 = -1$ → $dx = [5, -1]$
4. sprawdzenie jednej kratki bez wzoru: w_{12} stoi w z_1 przy $x_2 = 2$. Ruszam w_{12} o 1 → z_1 rośnie o 2 → L rośnie o $\delta_1 \cdot 2 = 4$ ✓

Zadania 7:

a) $x = [2, 1]$, $W = \begin{bmatrix} 1 & -1 \\ 2 & 0 \end{bmatrix}$, $\delta = [1, 3]$. Policz dW, db, dx.

b) 3 wejścia, 2 neurony: $x = [1, 0, -1]$, $W = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \end{bmatrix}$, $\delta = [2, -1]$. Policz dW, db, dx.

c) $x = [4, -1]$, $\delta = [3, 2]$. Policz tylko dW i db. Czy do tego potrzebujesz W?

8. Krok uczenia

$$W_{\text{nowe}} = W - \alpha\, dW, \qquad b_{\text{nowe}} = b - \alpha\, db$$

Od **każdej** wagi odejmujesz α razy jej gradient (z tego samego miejsca w macierzy). Wagi zmieniasz dopiero po całym backwardzie.

Zadania 8:

a) $W = \begin{bmatrix} 1 & 0 \\ 2 & -1 \end{bmatrix}$, $dW = \begin{bmatrix} 2 & 4 \\ 1 & -2 \end{bmatrix}$, $\alpha = 0{,}5$. Nowe W?

b) $b = [1, 1]$, $db = [2, -2]$, $\alpha = 0{,}5$. Nowe b?

c) Gradient wagi jest dodatni. Czy waga po kroku rośnie, czy maleje? Dlaczego tak ma być?

9. Cała sieć 2 → 2 → 1 (ReLU, sigmoida + BCE)

krok	co	wzór
1	warstwa 1 w przód	$z^1 = W^1 x + b^1,\ a^1 = \mathrm{ReLU}(z^1)$
2	warstwa 2 w przód	$z^2 = W^2 a^1 + b^2,\ p = \sigma(z^2)$
3	strata	$L = -[y \ln p + (1-y)\ln(1-p)]$
4	δ wyjścia	$\delta^2 = p - y$
5	gradienty warstwy 2	$dW^2 = \delta^2 (a^1)^T,\ db^2 = \delta^2,\ da^1 = (W^2)^T \delta^2$
6	przez ReLU	$\delta^1 = da^1 \odot \mathrm{maska}(z^1)$
7	gradienty warstwy 1	$dW^1 = \delta^1 x^T,\ db^1 = \delta^1$
8	krok	każde W i b: minus α razy gradient

Przykład rozwiązany. Dane: $x = [1, -1]$, $y = 0$, $W^1 = \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix}$, $b^1 = [0, 0]$, $W^2 = [1{,}5;\ 2]$ (jeden wiersz), $b^2 = -0{,}5$, $\alpha = 0{,}1$.

1. $z^1 = [2 - 1;\ -1 - 3] = [1;\ -4],\ a^1 = [1;\ 0]$
2. $z^2 = 1{,}5 \cdot 1 + 2 \cdot 0 - 0{,}5 = 1,\ p = \sigma(1) = 0{,}731$
3. $y = 0$: $L = -\ln(1 - 0{,}731) = 1{,}313$
4. $\delta^2 = 0{,}731 - 0 = 0{,}731$
5. $dW^2 = 0{,}731 \cdot [1, 0] = [0{,}731;\ 0],\ db^2 = 0{,}731,\ da^1 = [1{,}5 \cdot 0{,}731;\ 2 \cdot 0{,}731] = [1{,}097;\ 1{,}462]$
6. maska z $z^1 = [1, -4]$: $[1, 0]$ → $\delta^1 = [1{,}097;\ 0]$
7. dW^1: tabliczka $\delta^1 = [1{,}097, 0]$ z lewej, $x = [1, -1]$ u góry: $\begin{bmatrix} 1{,}097 & -1{,}097 \\ 0 & 0 \end{bmatrix}$, $db^1 = [1{,}097;\ 0]$
8. $W^1 = \begin{bmatrix} 2 - 0{,}110 & 1 + 0{,}110 \\ -1 & 3 \end{bmatrix} = \begin{bmatrix} 1{,}890 & 1{,}110 \\ -1 & 3 \end{bmatrix}$, $b^1 = [-0{,}110;\ 0]$, $W^2 = [1{,}5 - 0{,}073;\ 2] = [1{,}427;\ 2]$, $b^2 = -0{,}5 - 0{,}073 = -0{,}573$
9. sprawdzenie: z nowymi wagami $p = 0{,}595$, $L = 0{,}904$ (było 1,313) ✓

Zadanie 9 (najważniejsze w zeszycie): $x = [1, 2]$, $y = 1$, $W^1 = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix}$, $b^1 = [0, 0]$, $W^2 = [2;\ -1]$, $b^2 = 0$, $\alpha = 0{,}1$. Zrób kroki 1–8. (Masz: $\sigma(-2) = 0{,}119$, $\ln 0{,}119 = -2{,}127$.)

10. Jakobian: tabelka i „w dół kolumny”

krok	co robisz
1	tabelka: wiersz = wyjście y_i, kolumna = wejście x_j
2	w kratce (i, j): pochodna y_i po x_j (liczba stojąca przy x_j we wzorze na y_i; brak x_j → 0)
3	dla każdego x_j: idź w dół kolumny j, każdą liczbę pomnóż przez $\frac{\partial L}{\partial y_i}$ z jej wiersza, dodaj

Przykład rozwiązany: $y_1 = x_1 + 2x_3$, $y_2 = 3x_2 - x_3$, z góry $[2, 5]$.

1. tabelka: wiersz y_1: $[1, 0, 2]$; wiersz y_2: $[0, 3, -1]$

2. x_1: $2 \cdot 1 + 5 \cdot 0 = 2$; x_2: $2 \cdot 0 + 5 \cdot 3 = 15$; x_3: $2 \cdot 2 + 5 \cdot (-1) = -1$ → $[2, 15, -1]$

Zadanie 10: $y_1 = 2x_1 - x_2$, $y_2 = x_1 + 4x_2$, $y_3 = 3x_2$, z góry $\frac{\partial L}{\partial y} = [1, 0, 2]$. Tabelka (jaki rozmiar?) i $\frac{\partial L}{\partial x}$.

11. Kształty

rzecz	kształt (wiersze, kolumny)	zasada
x	$(d_{in}, 1)$	wektor pionowy
W	(d_{out}, d_{in})	wiersz = neuron
z, b, δ	$(d_{out}, 1)$	jedna liczba na neuron
dW	(d_{out}, d_{in})	gradient ma kształt tego, po czym liczysz
dx	$(d_{in}, 1)$	jak x
jakobian $\frac{\partial y}{\partial x}$	(d_y, d_x)	wiersz = y, kolumna = x

Mnożenie $(a, b) \cdot (b, c) = (a, c)$: środkowe liczby muszą być równe i znikają.

Zadanie 11: warstwa ma 10 wejść i 4 neurony. Podaj kształty x, W, b, z, dW, dx. Sprawdź, że δx^T ma kształt W.

12. Część 2: paczki, ADAM, He

12.1. Paczki (batch, mini-batch, SGD)

tryb	przepis
pełny zbiór (batch)	gradient każdej wagi = **średnia** gradientów ze wszystkich przykładów; jeden krok na epokę
mini-batch (np. 32)	średnia z 32 przykładów; krok po każdej paczce
SGD (pojedyncze przykłady)	krok po każdym przykładzie, z jego własnym gradientem

12.2. ADAM (krok t, gradient g, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$)

krok	wzór	po ludzku
1	$m = \beta_1 m + (1 - \beta_1) g$	średnia gradientów (kierunek); start $m = 0$
2	$v = \beta_2 v + (1 - \beta_2) g^2$	średnia kwadratów (wielkość); start $v = 0$
3	$\hat{m} = \frac{m}{1 - \beta_1^t}$, $\hat{v} = \frac{v}{1 - \beta_2^t}$	korekta, bo m, v startują od 0
4	$w = w - \alpha \frac{\hat{m}}{\sqrt{\hat{v}} + \varepsilon}$	krok ok. α, niezależnie od skali gradientu

Przykład rozwiązany: $t = 1$, $g = 0{,}5$, $\alpha = 0{,}01$.

1. $m = 0{,}1 \cdot 0{,}5 = 0{,}05$; $v = 0{,}001 \cdot 0{,}25 = 0{,}00025$

2. $\hat{m} = \frac{0{,}05}{0{,}1} = 0{,}5$; $\hat{v} = \frac{0{,}00025}{0{,}001} = 0{,}25$; $\sqrt{\hat{v}} = 0{,}5$

3. krok $= 0{,}01 \cdot \frac{0{,}5}{0{,}5} = 0{,}01$ (w pierwszym kroku zawsze ok. α)

12.3. Inicjalizacja He

$$\sigma_{He} = \sqrt{\frac{2}{d_{in}}}, \qquad \text{mnożnik wariancji na warstwę (ReLU)} = \frac{d_{in}\,\sigma^2}{2}$$

Mnożnik 1 → sygnał nie maleje ani nie rośnie. Mniejszy od 1 → zanika (plateau), większy → eksploduje.

Zadania 12:

a) Gradienty jednej wagi z 3 przykładów: $0{,}6$, $-0{,}3$, $0{,}3$. Jaki gradient w trybie pełnego zbioru i jaki krok przy $\alpha = 0{,}1$?

b) ADAM: krok 1 z $g = 0{,}4$, potem krok 2 z $g = 0{,}2$; $\alpha = 0{,}01$. Policz m, v, $\hat{m}$, $\hat{v}$ i krok w obu.

c) σ_{He} dla $d_{in} = 8$ i dla $d_{in} = 50$.

d) Mnożnik wariancji dla $d_{in} = 17$, $\sigma = 0{,}01$. Co się dzieje z sygnałem po 5 warstwach? A z He?

13. Notacja z wykładu (zamiana)

ćw. 3 (kod)	wykład 3–4
$\delta = p - y$ (odpowiedź minus prawda)	$\delta = y - \hat{y}$ (prawda minus odpowiedź)
$W = W - \alpha\,\delta\,x^T$	$w_{kj}(t+1) = w_{kj}(t) + \mu\,\delta_k\,a_j$
α	μ
$\delta^1 = (W^2)^T\delta^2 \odot f'(z^1)$	$\delta_j^1 = f'(z_j^1)\sum_k \delta_k^2 w_{kj}^2$

Przeciwny znak delty i przeciwny znak w kroku, więc wychodzi **ten sam** krok.

Zadanie 13: $\hat{y} = 0{,}119$, $y = 1$, $a_j = 2$, $\mu = 0{,}1$, $w = -1$. Policz nową wagę w notacji wykładu i w notacji ćw. 3. Czy wychodzi to samo?

R. Rozwiązania

1

a) wiersz 1: $1 \cdot 3 + 2 \cdot 1 = 5$; wiersz 2: $0 \cdot 3 + (-1) \cdot 1 = -1$ → $[5, -1]$

b) $\begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix}$, kształt $(3, 2)$ (było $(2, 3)$)

c) $[8, -5, 0]$

d) $\begin{bmatrix} 1 \cdot 3 & 1 \cdot 0 & 1 \cdot 2 \\ -2 \cdot 3 & -2 \cdot 0 & -2 \cdot 2 \end{bmatrix} = \begin{bmatrix} 3 & 0 & 2 \\ -6 & 0 & -4 \end{bmatrix}$, kształt $(2, 3)$

2

a) $0{,}8 \cdot 0{,}2 = 0{,}16$

b) $\sigma(0) = \frac{1}{1+1} = 0{,}5$; $\sigma' = 0{,}5 \cdot 0{,}5 = 0{,}25$

c) 0, 1, 1 (dla 100 też 1, nie 100)

d) $-\frac{1}{p} = -4$

3

a) $z = 3$, $L = 9$, $\frac{\partial L}{\partial z} = 2 \cdot 3 = 6$, $\frac{\partial z}{\partial w} = 2$, $\frac{\partial L}{\partial w} = 6 \cdot 2 = 12$. Sprawdzenie: $L = (2w + 1)^2$, pochodna $2(2w + 1) \cdot 2 = 4 \cdot 3 = 12$ ✓

b) droga przez a: $\frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial x} = 1 \cdot 3 = 3$; droga przez b: $1 \cdot 2x = 4$; suma 7. Sprawdzenie: $L = 3x + x^2$, $L' = 3 + 2x = 7$ ✓

4

a) $z_1 = 1 \cdot 2 + 1 \cdot (-1) + 0 = 1$; $z_2 = -2 \cdot 2 + 1 \cdot (-1) + 1 = -4$; $a = [1, 0]$

b) $z_1 = 2 - 3 - 1 = -2$; $z_2 = 1 + 1 + 0 = 2$; $a = [0, 2]$

5

a) $p = 0{,}5$; $L = -\ln 0{,}5 = 0{,}693$; $\delta = 0{,}5 - 1 = -0{,}5$

b) $p = \frac{1}{1+0{,}135} = 0{,}881$; $L = -\ln(1 - 0{,}881) = -\ln 0{,}119 = 2{,}127$; $\delta = 0{,}881$

c) $e^1 = 2{,}718$, $e^1 = 2{,}718$, $e^0 = 1$; suma $6{,}437$; $\hat{y} = [0{,}422;\ 0{,}422;\ 0{,}155]$; $L = -\ln 0{,}155 = 1{,}862$; $y = [0, 0, 1]$, $\delta = [0{,}422;\ 0{,}422;\ -0{,}845]$

6

a) maska $[1, 0, 0, 1]$ ($z = 0$ daje 0); $\frac{\partial L}{\partial z} = [1, 0, 0, 4]$

b) maska $[0, 0]$, gradient $[0, 0]$: oba neurony wyłączone, nie miały wpływu na wynik, więc ich wagi się nie zmienią („martwe neurony”)

7

a) $dW = \begin{bmatrix} 1 \cdot 2 & 1 \cdot 1 \\ 3 \cdot 2 & 3 \cdot 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 6 & 3 \end{bmatrix}$; $db = [1, 3]$; dx_1: kolumna $[1, 2]$: $1 \cdot 1 + 2 \cdot 3 = 7$; dx_2: kolumna $[-1, 0]$: $-1 \cdot 1 + 0 \cdot 3 = -1$ → $dx = [7, -1]$

b) $dW = \begin{bmatrix} 2 & 0 & -2 \\ -1 & 0 & 1 \end{bmatrix}$; $db = [2, -1]$; dx: kolumna $[1, -1]$: $2 + 1 = 3$; kolumna $[2, 1]$: $4 - 1 = 3$; kolumna $[0, 3]$: $0 - 3 = -3$ → $[3, 3, -3]$

c) $dW = \begin{bmatrix} 12 & -3 \\ 8 & -2 \end{bmatrix}$, $db = [3, 2]$. W nie jest potrzebne (potrzebne tylko do dx)

8

a) $\begin{bmatrix} 1-1 & 0-2 \\ 2-0{,}5 & -1+1 \end{bmatrix} = \begin{bmatrix} 0 & -2 \\ 1{,}5 & 0 \end{bmatrix}$

b) $[1-1;\ 1+1] = [0, 2]$

c) maleje. Dodatni gradient znaczy: gdy waga rośnie, L rośnie. Chcemy mniejszego L, więc wagę zmniejszamy.

9

1. $z^1 = [1-2;\ 0+2] = [-1;\ 2]$, $a^1 = [0;\ 2]$

2. $z^2 = 2 \cdot 0 + (-1) \cdot 2 + 0 = -2$, $p = \sigma(-2) = 0{,}119$

3. $y = 1$: $L = -\ln 0{,}119 = 2{,}127$

4. $\delta^2 = 0{,}119 - 1 = -0{,}881$

5. $dW^2 = -0{,}881 \cdot [0, 2] = [0;\ -1{,}762]$, $db^2 = -0{,}881$, $da^1 = [2 \cdot (-0{,}881);\ -1 \cdot (-0{,}881)] = [-1{,}762;\ 0{,}881]$

6. maska z $z^1 = [-1, 2]$: $[0, 1]$ → $\delta^1 = [0;\ 0{,}881]$

7. $dW^1 = \begin{bmatrix} 0 \cdot 1 & 0 \cdot 2 \\ 0{,}881 \cdot 1 & 0{,}881 \cdot 2 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0{,}881 & 1{,}762 \end{bmatrix}$, $db^1 = [0;\ 0{,}881]$

8. $W^1 = \begin{bmatrix} 1 & -1 \\ -0{,}088 & 0{,}824 \end{bmatrix}$, $b^1 = [0;\ -0{,}088]$, $W^2 = [2;\ -1 + 0{,}176] = [2;\ -0{,}824]$, $b^2 = 0 + 0{,}088 = 0{,}088$

9. sprawdzenie: z nowymi wagami $p = 0{,}245$, $L = 1{,}406$ (było 2,127) ✓. Wiersz 1 W^1 się nie zmienił, bo neuron 1 był wyłączony.

10

tabelka 3×2: $\begin{bmatrix} 2 & -1 \\ 1 & 4 \\ 0 & 3 \end{bmatrix}$; x_1: $1 \cdot 2 + 0 \cdot 1 + 2 \cdot 0 = 2$; x_2: $1 \cdot (-1) + 0 \cdot 4 + 2 \cdot 3 = 5$ → $[2, 5]$

11

x: $(10, 1)$; W: $(4, 10)$; b, z: $(4, 1)$; dW: $(4, 10)$; dx: $(10, 1)$. δx^T: $(4, 1) \cdot (1, 10) = (4, 10)$ ✓

12

a) średnia $\frac{0{,}6 - 0{,}3 + 0{,}3}{3} = 0{,}2$; krok $-0{,}1 \cdot 0{,}2 = -0{,}02$

b) krok 1: $m = 0{,}04$, $v = 0{,}00016$, $\hat{m} = 0{,}4$, $\hat{v} = 0{,}16$, $\sqrt{\hat{v}} = 0{,}4$, krok $0{,}01$. Krok 2: $m = 0{,}9 \cdot 0{,}04 + 0{,}1 \cdot 0{,}2 = 0{,}056$; $v = 0{,}999 \cdot 0{,}00016 + 0{,}001 \cdot 0{,}04 = 0{,}0001998$; $\hat{m} = \frac{0{,}056}{1 - 0{,}81} = 0{,}295$; $\hat{v} = \frac{0{,}0001998}{1 - 0{,}998} = 0{,}100$; $\sqrt{\hat{v}} = 0{,}316$; krok $0{,}01 \cdot \frac{0{,}295}{0{,}316} = 0{,}0093$

c) $\sqrt{2/8} = \sqrt{0{,}25} = 0{,}5$; $\sqrt{2/50} = \sqrt{0{,}04} = 0{,}2$

d) $\frac{17 \cdot 0{,}0001}{2} = 0{,}00085$; odchylenie razy $\sqrt{0{,}00085} = 0{,}029$ na warstwę, po 5 warstwach $0{,}029^5 \approx 2 \cdot 10^{-8}$ – sygnał praktycznie znika (plateau). He: $\sigma^2 = 2/17$, mnożnik $\frac{17 \cdot 2/17}{2} = 1$ – sygnał się zachowuje.

13

wykład: $\delta = 1 - 0{,}119 = 0{,}881$, $w = -1 + 0{,}1 \cdot 0{,}881 \cdot 2 = -0{,}824$. Ćw. 3: $\delta = 0{,}119 - 1 = -0{,}881$, $w = -1 - 0{,}1 \cdot (-0{,}881) \cdot 2 = -0{,}824$. To samo ✓ (to jest w_2^2 z zadania 9).